TP HD/PCA — Construire le cluster Proxmox, le tester en cas de panne

GRETA de l'Essonne — Titre Professionnel AIS — Bloc 2 : Conception et évolution

Formateur : Samir KECHEMIR

Charles Maduba — Groupe 3 (travail réalisé en groupe de 4 stagiaires)

Séance A : lundi 5 octobre 2026 — Parties 1 et 2. Jeudi 8 octobre 2026 — Parties 3 et 4.

Synthèse de la séance

Partie	Contenu	État
1	Préparer 3 serveurs Proxmox (pve1, pve2, pve3)	Terminé
2	Créer le cluster et vérifier le quorum	Terminé
3	Stockage partagé (NFS)	Terminé
4	HA, test de panne, mesure du RTO	Terminé (RTO : 2 min 17 s, cible 15 min : conforme)

Nœud	Nom	Adresse IP
Nœud 1 (existant)	pve (alias pve1)	192.168.56.200
Nœud 2	pve2	192.168.56.201
Nœud 3	pve3	192.168.56.202

PARTIE 1 — Préparer les 3 serveurs

1.1 — Création de pve2 et pve3

Remarque : pve2 et pve3 n'ont pas été créés par clonage de pve1. Ils ont été installés à neuf à partir de l'ISO Proxmox VE, dans VirtualBox, sur le même réseau Host-Only 192.168.56.0/24. Il n'y a donc pas de captures de la fenêtre de clonage.

Conséquence : chaque nœud a eu dès l'installation ses propres clés SSH et son propre identifiant machine (machine-id). L'étape 1.3 (régénération des clés et du machine-id) n'a pas été nécessaire ; nous avons seulement vérifié que les trois identifiants sont bien différents.

1.2 — Nom, fichier /etc/hosts et adresse IP de chaque nœud

```
root@pve:~# cat /etc/hosts
127.0.0.1 localhost.localdomain localhost
192.168.56.200 pve.local.lan pve pve1
192.168.56.201 pve2.lab.local pve2
192.168.56.202 pve3.lab.local pve3

# The following lines are desirable for IPv6 capable hosts

::1     ip6-localhost ip6-loopback
fe00::0 ip6-localnet
ff00::0 ip6-mcastprefix
ff02::1 ip6-allnodes
ff02::2 ip6-allrouters
ff02::3 ip6-allhosts
root@pve:~# hostname -i
192.168.56.200
root@pve:~# cat /etc/machine-id
f4679ee0fbab48b2bebf6f1afdb5e526
root@pve:~#
```

pve1 : /etc/hosts avec les 3 nœuds, hostname -i = 192.168.56.200, machine-id

```
root@pve2:~# cat /etc/hosts
127.0.0.1 localhost.localdomain localhost
192.168.56.201 pve2.lab.local pve2
192.168.56.200 pve.local.lan pve pve1
192.168.56.202 pve3.lab.local pve3

# The following lines are desirable for IPv6 capable hosts

::1     ip6-localhost ip6-loopback
fe00::0 ip6-localnet
ff00::0 ip6-mcastprefix
ff02::1 ip6-allnodes
ff02::2 ip6-allrouters
ff02::3 ip6-allhosts
root@pve2:~# hostname -i
192.168.56.201
root@pve2:~# ip -br a
lo               UNKNOWN        127.0.0.1/8 ::1/128
enp0s3           UP
enp0s8           UP             10.0.3.15/24 fd17:625c:f037:3:a00:27ff:feef:ef90/64 fe80::a00:27ff:feef:ef90/64
vmbr0            UP             192.168.56.201/24 fe80::a00:27ff:fef6:a204/64
root@pve2:~#
```

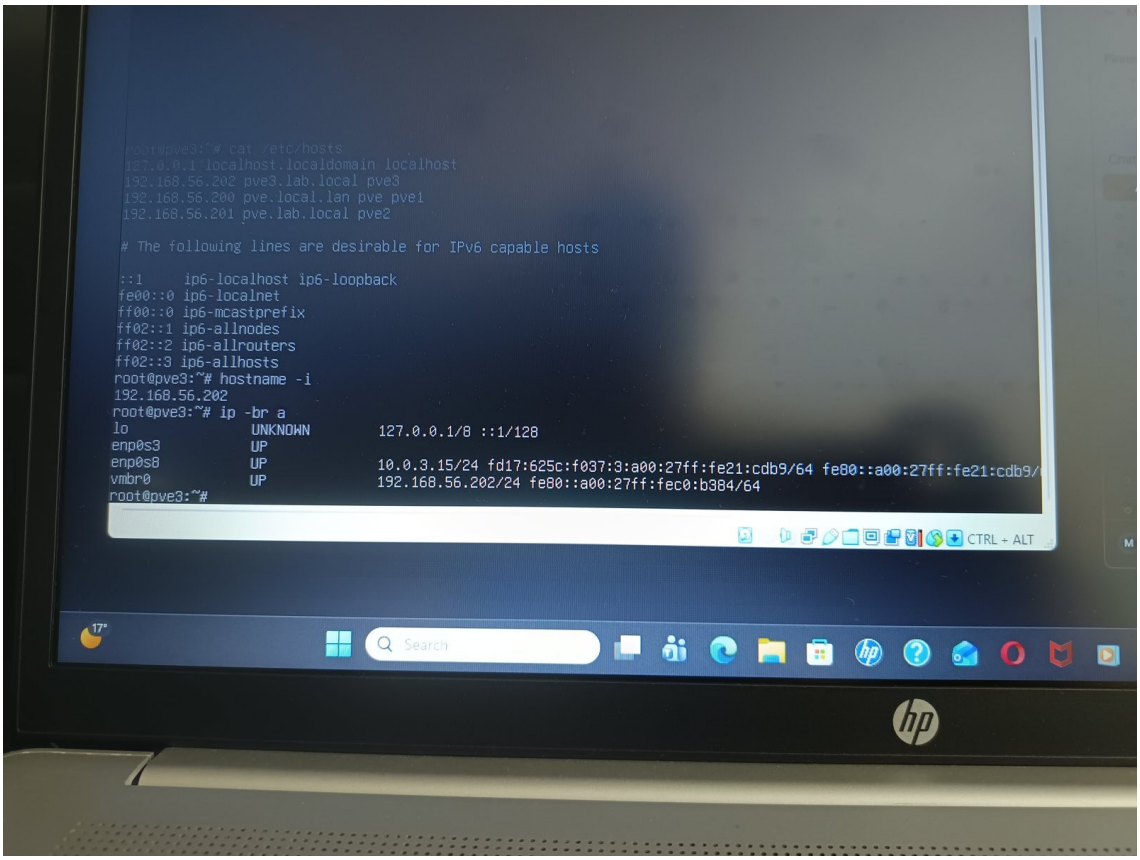
pve2 : /etc/hosts, hostname -i et ip -br a (vmbr0 = 192.168.56.201)

```
root@pve3:~# sed -i 's/201 pve.lab.local/201 pve2.lab.local/' /etc/hosts
root@pve3:~# cat /etc/hosts
127.0.0.1 localhost.localdomain localhost
192.168.56.202 pve3.lab.local pve3
192.168.56.200 pve.local.lan pve pve1
192.168.56.201 pve2.lab.local pve2

# The following lines are desirable for IPv6 capable hosts

::1     ip6-localhost ip6-loopback
fe00::0 ip6-localnet
ff00::0 ip6-mcastprefix
ff02::1 ip6-allnodes
ff02::2 ip6-allrouters
ff02::3 ip6-allhosts
root@pve3:~#
```

pve3 : contenu de /etc/hosts



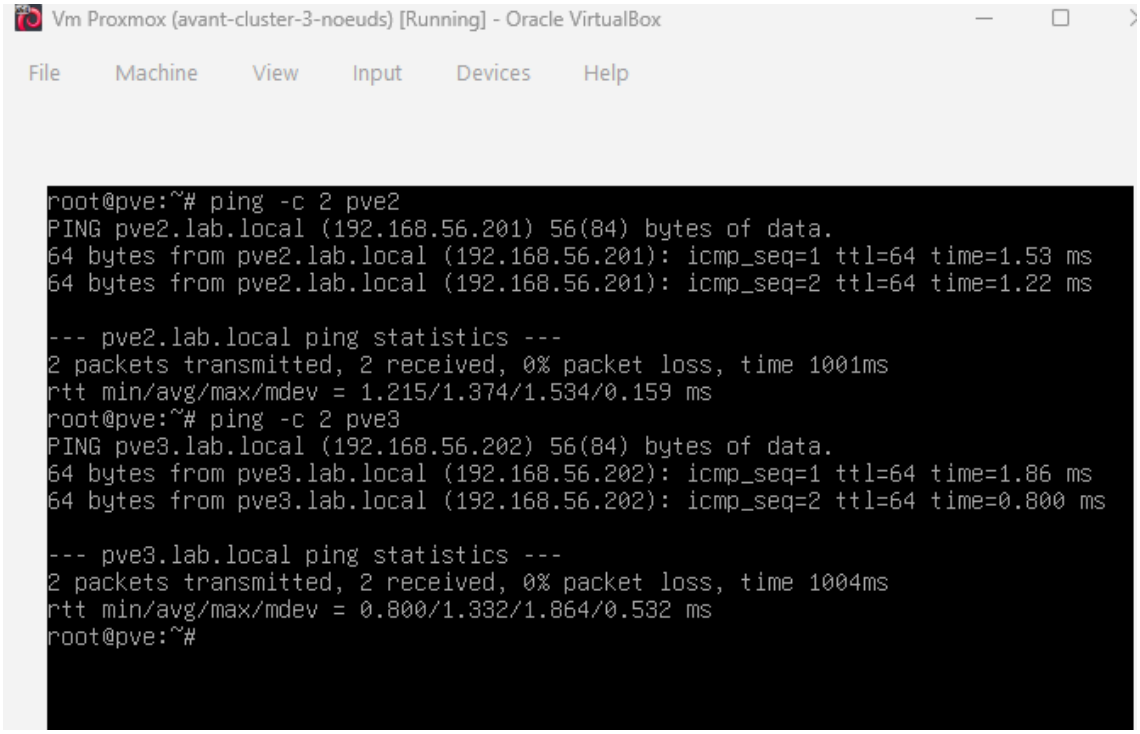
pve3 : hostname -i et ip -br a (vmbr0 = 192.168.56.202)

1.3 — Les 3 machine-id

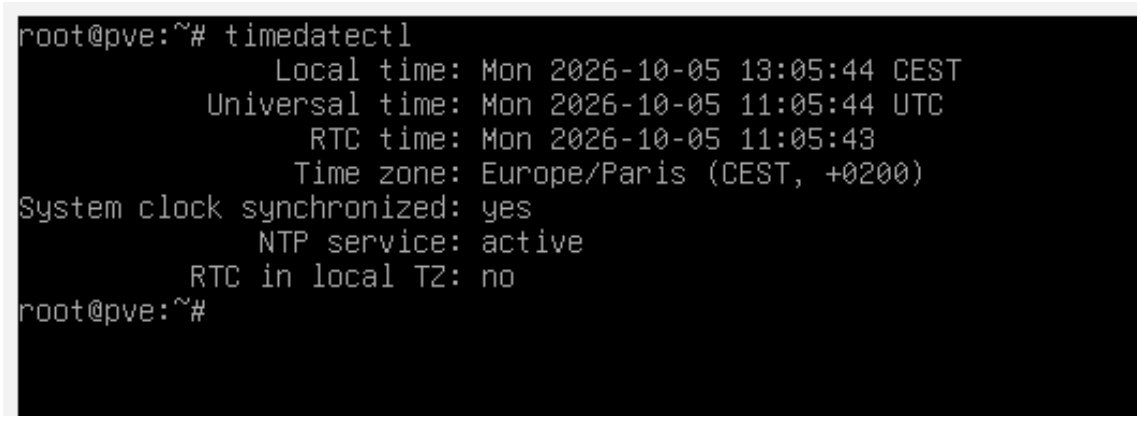
Nœud	machine-id
pve1	f4679ee0fbab48b2bebf6f1afdb5e526
pve2	0c5c5b5745d04cf2985687e8c53da75f
pve3	c895ad2836d5419fb7c48d0328d078e3

Les trois identifiants sont différents (captures ci-dessus pour pve1, ci-dessous pour pve2 et pve3).

1.4 — Les 3 nœuds se voient (ping, heure, nœuds vides)



pve1 : ping -c 2 pve2 et ping -c 2 pve3 — réponse avec la bonne adresse IP



pve1 : timedatectl — System clock synchronized: yes

```
root@pve2:~# cat /etc/machine-id
0c5c5b5745d04cf2985687e8c53da75f
root@pve2:~# ping -c 2 pve1
PING pve.local.lan (192.168.56.200) 56(84) bytes of data.
64 bytes from pve.local.lan (192.168.56.200): icmp_seq=1 ttl=64 time=1.33 ms
64 bytes from pve.local.lan (192.168.56.200): icmp_seq=2 ttl=64 time=0.620 ms

--- pve.local.lan ping statistics ---
2 packets transmitted, 2 received, 0% packet loss, time 1003ms
rtt min/avg/max/mdev = 0.620/0.974/1.329/0.354 ms
root@pve2:~# ping -c 2 pve3
PING pve3.lab.local (192.168.56.202) 56(84) bytes of data.
64 bytes from pve3.lab.local (192.168.56.202): icmp_seq=1 ttl=64 time=5.83 ms
64 bytes from pve3.lab.local (192.168.56.202): icmp_seq=2 ttl=64 time=0.584 ms

--- pve3.lab.local ping statistics ---
2 packets transmitted, 2 received, 0% packet loss, time 1107ms
rtt min/avg/max/mdev = 0.584/3.207/5.831/2.623 ms
root@pve2:~# timedatectl
               Local time: Mon 2026-10-05 12:42:18 CEST
           Universal time: Mon 2026-10-05 10:42:18 UTC
                 RTC time: Mon 2026-10-05 10:42:18
                Time zone: Europe/Paris (CEST, +0200)
System clock synchronized: yes
              NTP service: active
          RTC in local TZ: no
root@pve2:~# qm list
root@pve2:~# pct list
root@pve2:~#
```

pve2 : machine-id, ping pve1 et pve3, timedatectl (synchronisé), qm list et pct list vides

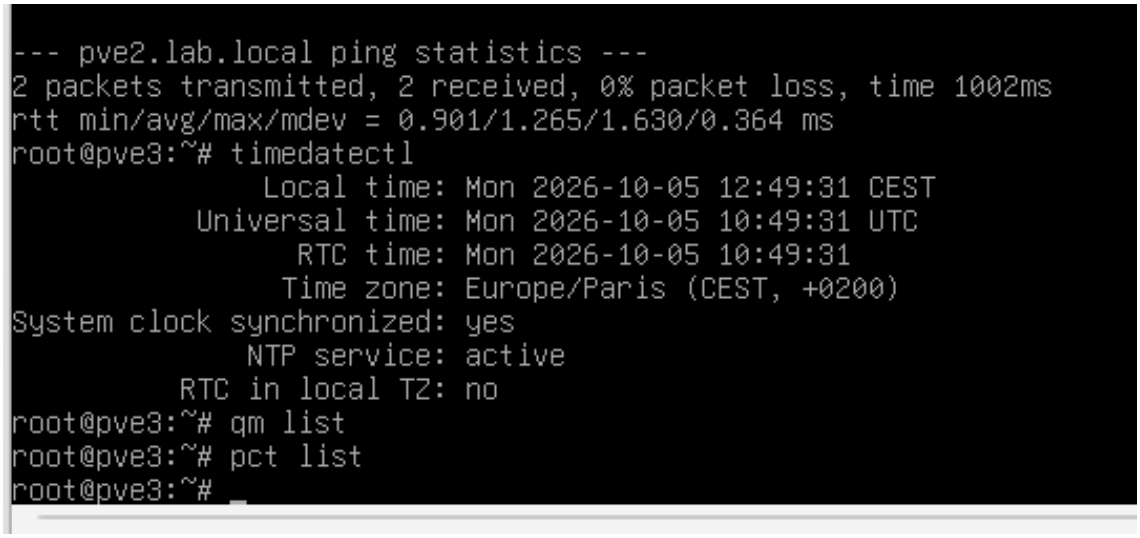
```
192.168.56.202
root@pve3:~# ip -br a
lo               UNKNOWN        127.0.0.1/8 ::1/128
enp0s3           UP
enp0s8           UP             10.0.3.15/24 fd17:625c:f037:3:a00:27ff:fe21:cdb9/64 fe80::a00:27ff:fe21:cdb9
vmbr0            UP             192.168.56.202/24 fe80::a00:27ff:fec0:b384/64
root@pve3:~# sed -i 's/201 pve.lab.local/201 pve2.lab.local/' /etc/hosts
root@pve3:~# cat /etc/hosts
127.0.0.1 localhost.localdomain localhost
192.168.56.202 pve3.lab.local pve3
192.168.56.200 pve.local.lan pve pve1
192.168.56.201 pve2.lab.local pve2

# The following lines are desirable for IPv6 capable hosts

::1     ip6-localhost ip6-loopback
fe00::0 ip6-localnet
ff00::0 ip6-mcastprefix
ff02::1 ip6-allnodes
ff02::2 ip6-allrouters
ff02::3 ip6-allhosts
root@pve3:~# cat /etc/machine-id
c895ad2836d5419fb7c48d0328d078e3
root@pve3:~# ping -c 2 pve1
PING pve.local.lan (192.168.56.200) 56(84) bytes of data.
64 bytes from pve.local.lan (192.168.56.200): icmp_seq=1 ttl=64 time=2.37 ms
64 bytes from pve.local.lan (192.168.56.200): icmp_seq=2 ttl=64 time=0.647 ms

--- pve.local.lan ping statistics ---
2 packets transmitted, 2 received, 0% packet loss, time 1002ms
rtt min/avg/max/mdev = 0.647/1.508/2.370/0.861 ms
root@pve3:~# ping -c 2 pve2
PING pve2.lab.local (192.168.56.201) 56(84) bytes of data.
64 bytes from pve2.lab.local (192.168.56.201): icmp_seq=1 ttl=64 time=1.63 ms
64 bytes from pve2.lab.local (192.168.56.201): icmp_seq=2 ttl=64 time=0.901 ms
```

pve3 : ip -br a, /etc/hosts, machine-id, ping pve1 et pve2

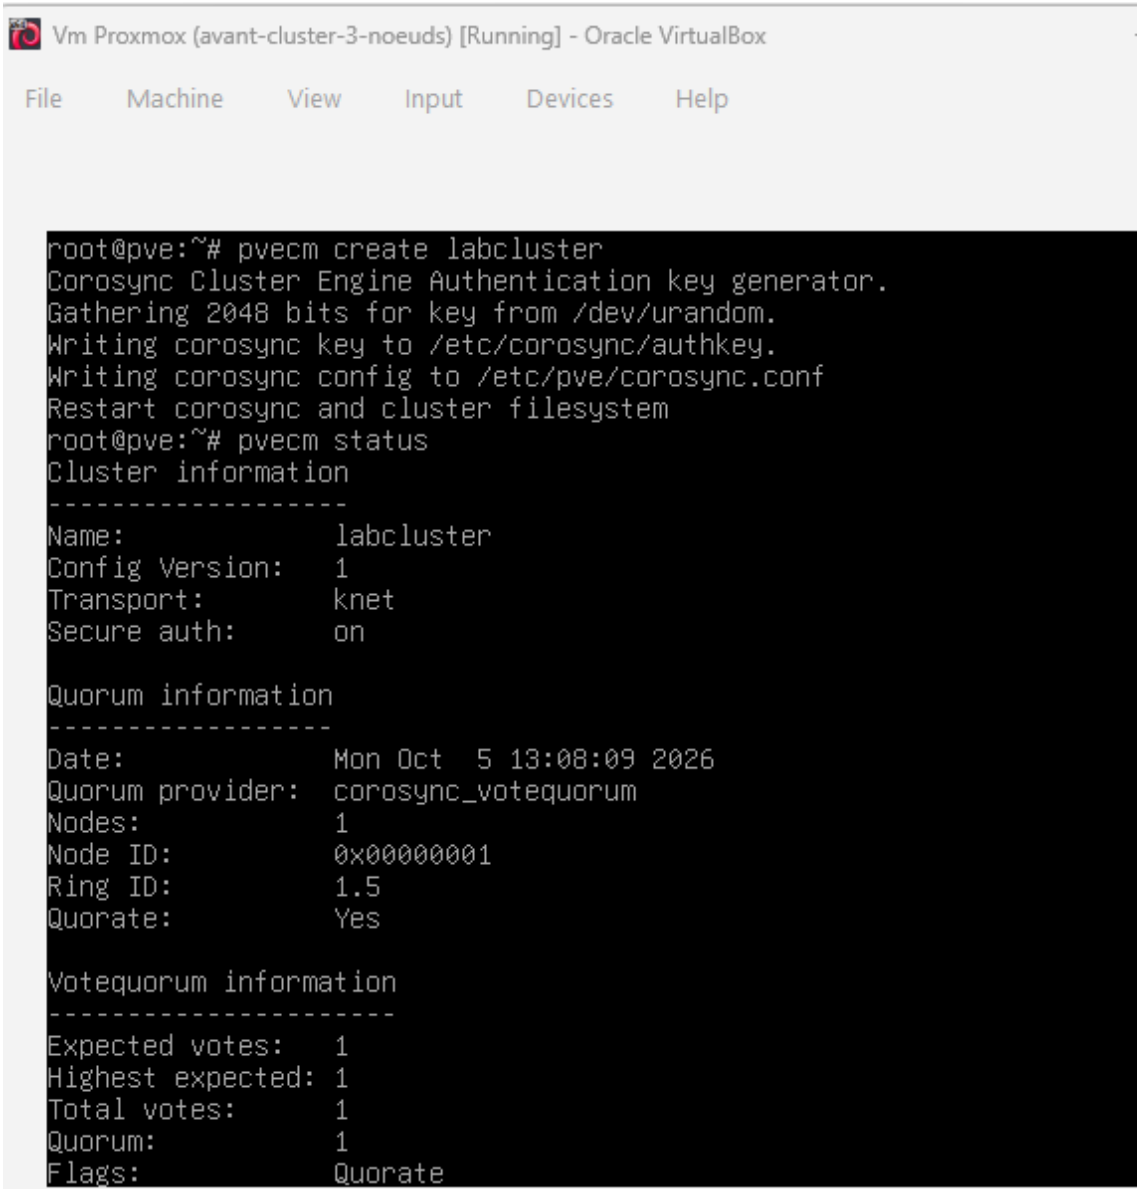


pve3 : timedatectl (synchronisé), qm list et pct list vides

Résultat : chaque nom répond avec la bonne adresse IP, l'horloge est synchronisée sur les 3 nœuds, et pve2 et pve3 ne contiennent aucune VM ni aucun conteneur (condition pour rejoindre le cluster).

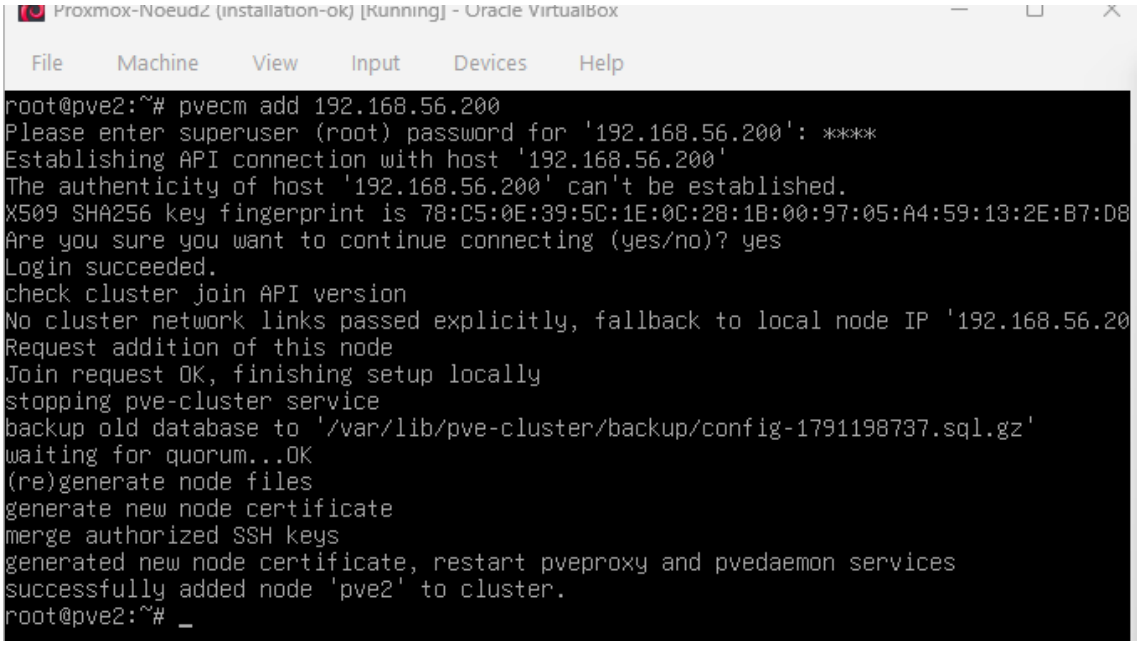
PARTIE 2 — Créer le cluster

2.1 / 2.2 — Création du cluster sur pve1 et premier pvecm status



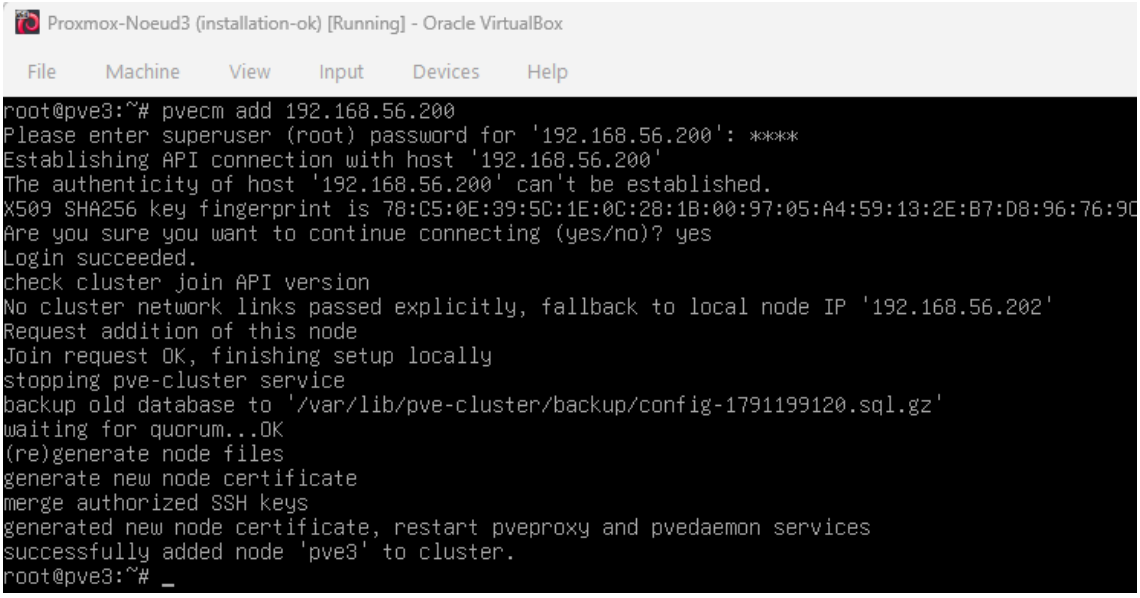
pvecm create labcluster puis pvecm status : Nodes: 1, Quorate: Yes

2.3 — Ajout de pve2



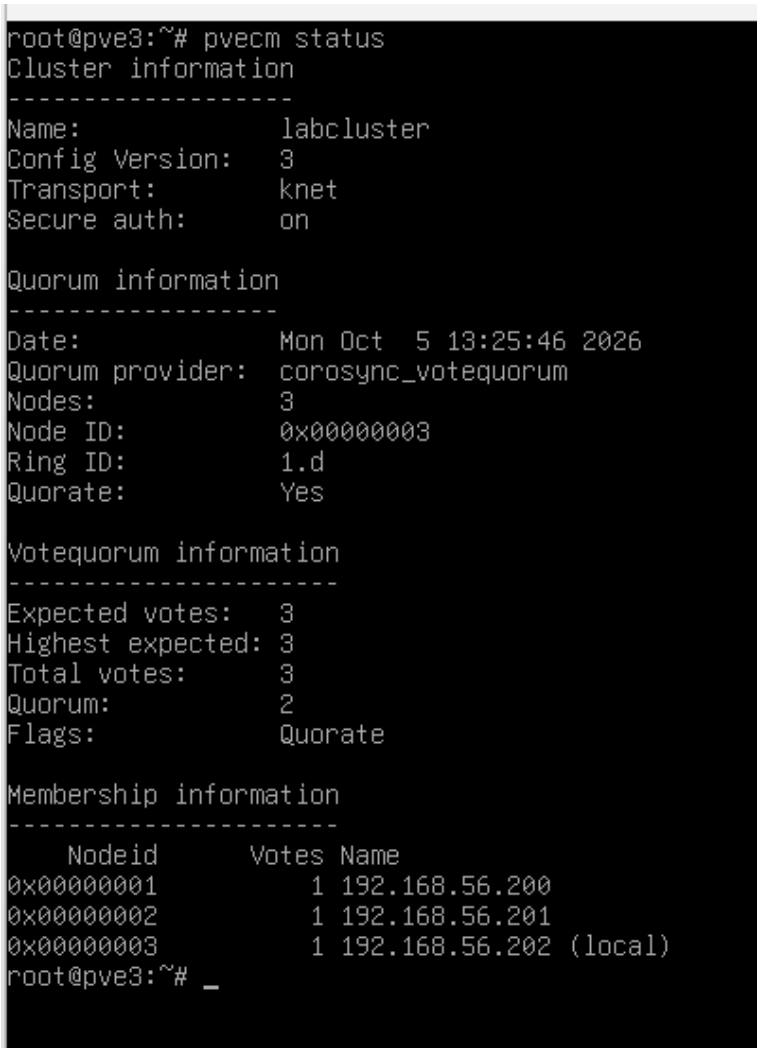
pve2 : pvecm add 192.168.56.200 — nœud ajouté au cluster

2.4 — Ajout de pve3



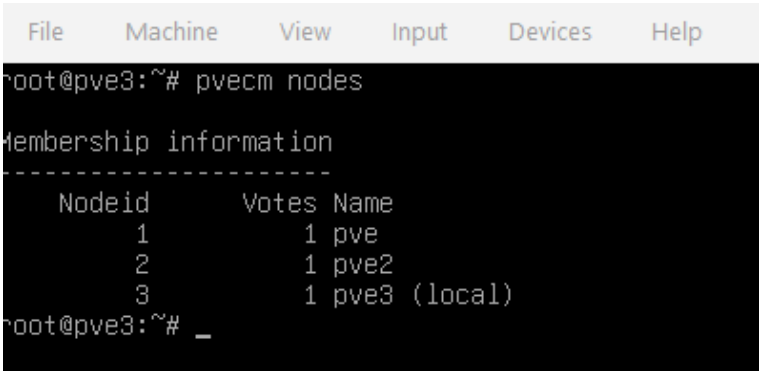
pve3 : pvecm add 192.168.56.200 — nœud ajouté au cluster

2.5 — pvecm status avec les 3 nœuds



Nodes: 3, Total votes: 3, Quorum: 2, Quorate: Yes

2.6 — pvecm nodes



pve, pve2 et pve3 listés

2.7 — Expérience : le quorum en direct

Situation	Votes présents	Quorate	Observation

3 nœuds allumés	3 / 3	Yes	Cluster normal
pve3 éteint	2 / 3	Yes	Le cluster continue de fonctionner
pve2 et pve3 éteints	1 / 3	No	« Activity blocked » : le cluster refuse d'agir
pve2 et pve3 rallumés	3 / 3	Yes	Retour à la normale après 1 à 2 minutes

```
root@pve:~# pvecm status
Cluster information
-------------------
Name:             labcluster
Config Version:   3
Transport:        knet
Secure auth:      on

Quorum information
------------------
Date:             Mon Oct  5 13:29:31 2026
Quorum provider:  corosync_votequorum
Nodes:            2
Node ID:          0x00000001
Ring ID:          1.11
Quorate:          Yes

Votequorum information
----------------------
Expected votes:   3
Highest expected: 3
Total votes:      2
Quorum:           2
Flags:            Quorate

Membership information
----------------------
    Nodeid      Votes Name
0x00000001          1 192.168.56.200 (local)
0x00000002          1 192.168.56.201
```

pve3 éteint : Nodes: 2, Quorate: Yes

```
root@pve:~# pvecm status
Cluster information
-------------------
Name:             labcluster
Config Version:   3
Transport:        knet
Secure auth:      on

Quorum information
------------------
Date:             Mon Oct  5 13:32:30 2026
Quorum provider:  corosync_votequorum
Nodes:            1
Node ID:          0x00000001
Ring ID:          1.15
Quorate:          No

Votequorum information
----------------------
Expected votes:   3
Highest expected: 3
Total votes:      1
Quorum:           2 Activity blocked
Flags:

Membership information
----------------------
    Nodeid      Votes Name
0x00000001          1 192.168.56.200 (local)
root@pve:~# _
```

pve2 et pve3 éteints : Nodes: 1, Quorate: No, « Activity blocked »

```
root@pve:~# pvecm status
Cluster information
-------------------
Name:             labcluster
Config Version:   3
Transport:        knet
Secure auth:      on

Quorum information
------------------
Date:             Mon Oct  5 13:44:12 2026
Quorum provider:  corosync_votequorum
Nodes:            3
Node ID:          0x00000001
Ring ID:          1.1e
Quorate:          Yes

Votequorum information
----------------------
Expected votes:   3
Highest expected: 3
Total votes:      3
Quorum:           2
Flags:            Quorate

Membership information
----------------------
    Nodeid      Votes Name
0x00000001          1 192.168.56.200 (local)
0x00000002          1 192.168.56.201
```

pve2 et pve3 rallumés : Nodes: 3, Quorate: Yes

Question : pourquoi 2 nœuds sur 3 suffisent, alors que 1 nœud sur 3 ne suffit pas ?

Le quorum est la majorité des votes : quorum = (nombre de nœuds ÷ 2) arrondi à l'inférieur + 1. Avec 3 nœuds : 3 ÷ 2 = 1,5 → 1, puis 1 + 1 = 2 votes.

Avec 2 nœuds allumés, on a 2 votes ≥ 2 : le cluster a le quorum et continue de fonctionner.

Avec 1 seul nœud, on a 1 vote < 2 : pas de quorum, le cluster bloque les actions (« Activity blocked »). C'est la protection contre le split-brain : un nœud isolé ne doit pas agir seul, car il ne sait pas si les autres fonctionnent encore de leur côté. S'il le faisait, deux parties du cluster pourraient démarrer la même VM en même temps et abîmer ses données.

PARTIE 3 — Stockage partagé (NFS)

Réalisée en ligne de commande (pvesm / qm) plutôt que dans l'interface web : avec les 3 nœuds allumés, le PC hôte n'avait pas assez de mémoire pour ouvrir un navigateur. Le résultat est identique, l'interface web utilise les mêmes commandes.

3.1 — Installation du serveur NFS sur pve et création du dossier partagé

Commandes : apt install -y nfs-kernel-server puis mkdir -p /srv/nfs/vmstore. Avant l'installation, nous avons vérifié l'accès Internet de pve (ping deb.debian.org : 0 % de perte).

```
Reading package lists... Done
Building dependency tree... Done
Reading state information... Done
The following NEW packages will be installed:
  nfs-kernel-server
0 upgraded, 1 newly installed, 0 to remove and 149 not upgraded.
Need to get 152 kB of archives.
After this operation, 626 kB of additional disk space will be used.
Get:1 http://ftp.fr.debian.org/debian bookworm/main amd64 nfs-kernel-server amd6
4 1:2.6.2-4+deb12u1 [152 kB]
Fetched 152 kB in 0s (1,569 kB/s)
Selecting previously unselected package nfs-kernel-server.
(Reading database ... 46310 files and directories currently installed.)
Preparing to unpack .../nfs-kernel-server_1%3a2.6.2-4+deb12u1_amd64.deb ...
Unpacking nfs-kernel-server (1:2.6.2-4+deb12u1) ...
Setting up nfs-kernel-server (1:2.6.2-4+deb12u1) ...
Created symlink /etc/systemd/system/nfs-client.target.wants/nfs-blkmap.service →
 /lib/systemd/system/nfs-blkmap.service.
Created symlink /etc/systemd/system/multi-user.target.wants/nfs-server.service →
 /lib/systemd/system/nfs-server.service.
nfs-mountd.service is a disabled or a static unit, not starting it.
nfsdcld.service is a disabled or a static unit, not starting it.

Creating config file /etc/exports with new version

Creating config file /etc/default/nfs-kernel-server with new version
Processing triggers for man-db (2.11.2-2) ...
root@pve:~# mkdir -p /srv/nfs/vmstore
root@pve:~#
```

Installation de nfs-kernel-server sans erreur, création de /srv/nfs/vmstore

3.2 — Déclaration du partage (exportfs -v)

Ligne ajoutée dans /etc/exports : /srv/nfs/vmstore 192.168.56.0/24(rw,sync,no_subtree_check,no_root_squash), puis exportfs -ra. Seul le réseau du lab (192.168.56.0/24) peut accéder au partage.

```
root@pve:~# mkdir -p /srv/nfs/vmstore
root@pve:~# echo '/srv/nfs/vmstore 192.168.56.0/24(rw,sync,no_subtree_check,no_r
oot_squash)' >> /etc/exports
root@pve:~# cat /etc/exports
# /etc/exports: the access control list for filesystems which may be exported
#               to NFS clients.  See exports(5).
#
# Example for NFSv2 and NFSv3:
# /srv/homes       hostname1(rw,sync,no_subtree_check) hostname2(ro,sync,no_subt
ree_check)
#
# Example for NFSv4:
# /srv/nfs4        gss/krb5i(rw,sync,fsid=0,crossmnt,no_subtree_check)
# /srv/nfs4/homes  gss/krb5i(rw,sync,no_subtree_check)
#
/srv/nfs/vmstore 192.168.56.0/24(rw,sync,no_subtree_check,no_root_squash)
root@pve:~# exportfs-ra
-bash: exportfs-ra: command not found
root@pve:~# exportfs -ra
root@pve:~# exportfs -v
/srv/nfs/vmstore
                192.168.56.0/24(sync,wdelay,hide,no_subtree_check,sec=sys,rw,sec
ure,no_root_squash,no_all_squash)
root@pve:~#
```

cat /etc/exports et exportfs -v : le partage /srv/nfs/vmstore est actif

3.3 — Stockage nfs-shared ajouté au cluster (visible sur les 3 nœuds)

Commande sur pve : pvesm add nfs nfs-shared --server 192.168.56.200 --export /srv/nfs/vmstore --content images. Le stockage est défini au niveau du Datacenter : pve2 et pve3 le reçoivent automatiquement.

```
root@pve:~# systemctl restart pve-cluster
root@pve:~# pvesm add nfs nfs-shared --server 192.168.56.200 --export /srv/nfs/v
mstore --content images
root@pve:~# pvesm status
Name             Type     Status           Total            Used       Availabl
e        %
local             dir     active        13242248         4698152         784962
0   35.48%
local-lvm     lvmthin     active        11460608         9796527         166408
0   85.48%
nfs-shared        nfs     active        13242368         4698112         784998
4   35.48%
root@pve:~#
```

pve : nfs-shared de type nfs, statut active

```
root@pve2:~# pvesm status
Name             Type     Status           Total            Used       Available        %
local             dir     active        15153508         2950036        11411920   19.47%
local-lvm     lvmthin     active        13402112               0        13402112    0.00%
nfs-shared        nfs     active        13242368         4700160         7847424   35.49%
root@pve2:~#
```

pve2 : nfs-shared actif

```
root@pve3:~# pvesm status
Name             Type     Status           Total            Used       Available        %
local             dir     active        15153508         2941592        11420364   19.41%
local-lvm     lvmthin     active        13402112               0        13402112    0.00%
nfs-shared        nfs     active        13242368         4700160         7847424   35.49%
root@pve3:~# _
```

pve3 : nfs-shared actif

Remarque : une première tentative a échoué avec « cfs-lock … error: no quorum » alors que pvecm status indiquait Quorate: Yes. Le service de configuration du cluster (pmxcfs) était resté en lecture seule après une perte de contact entre les nœuds. Résolu par systemctl restart pve-cluster.

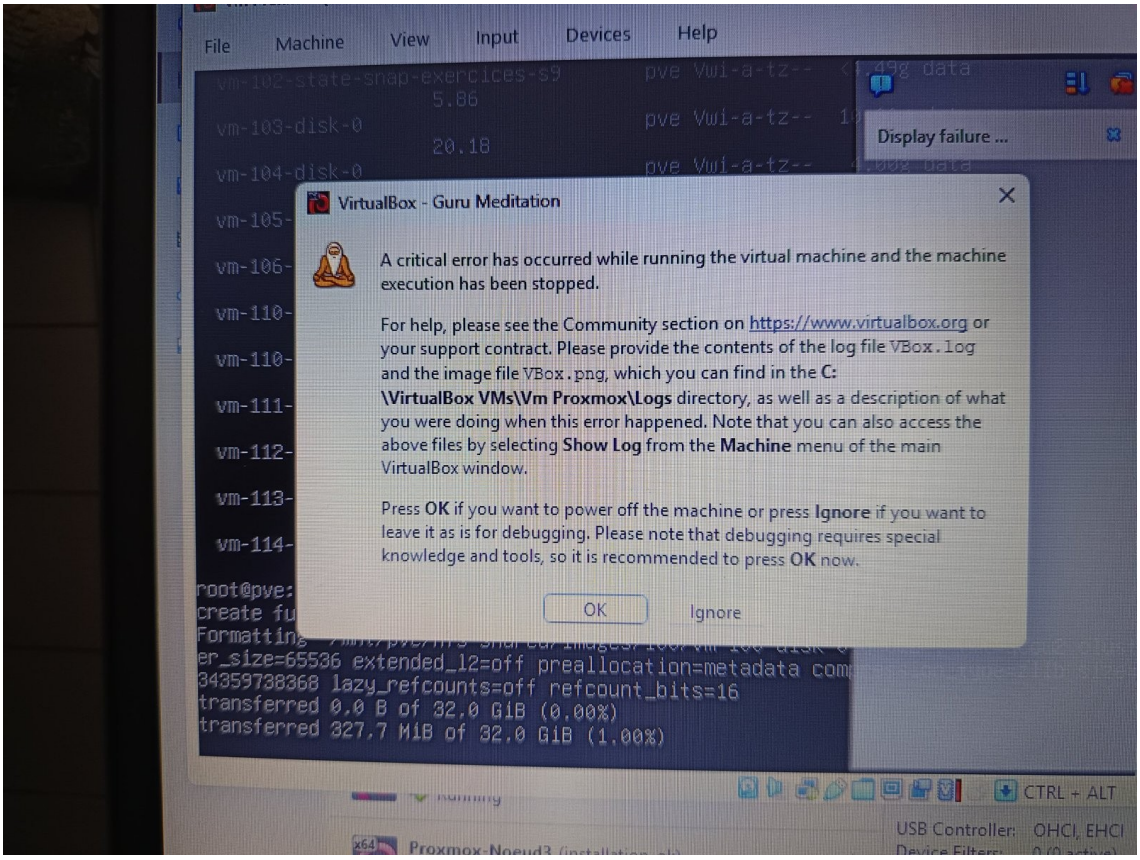
3.4 — Disque de VM-Test placé sur nfs-shared

VM-Test est la VM 100 (512 Mo de RAM, pas d'ISO dans le lecteur CD). Son disque de 32 Go était sur local-lvm.

```
root@pve:~# qm list
      VMID NAME                 STATUS     MEM(MB)    BOOTDISK(GB) PID
       100 VM-Test              stopped    512              32.00 0
       101 VM-Debian-S8         stopped    2048             10.00 0
       102 VM-Clone-S8          stopped    2048             10.00 0
       103 VM-FullClone-S8      stopped    2048             10.00 0
root@pve:~# qm config 100
boot: order=scsi0;ide2;net0
cores: 1
cpu: x86-64-v2-AES
ide2: none,media=cdrom
memory: 512
meta: creation-qemu=9.2.0,ctime=1781899361
name: VM-Test
net0: virtio=BC:24:11:BD:12:A6,bridge=vmbr0,firewall=1
numa: 0
ostype: l26
scsi0: local-lvm:vm-100-disk-0,iothread=1,size=32G
scsihw: virtio-scsi-single
smbios1: uuid=873adaa6-6221-4530-ab7d-0893abfc0781
sockets: 1
vmgenid: a15854c3-d94a-4f53-9bf1-681256e55e24
root@pve:~# _
```

qm list et qm config 100 avant l'opération : disque sur local-lvm, 32 Go

Incident : le déplacement du disque (qm disk move, équivalent de « Move Storage ») a provoqué un plantage de la VM pve (« Guru Meditation » VirtualBox) à 1 %, par manque de ressources sur le PC hôte. Le disque d'origine n'a pas été touché (la suppression n'a lieu qu'après une copie réussie). Après redémarrage de pve, nous avons supprimé la copie incomplète avec pvesm free.

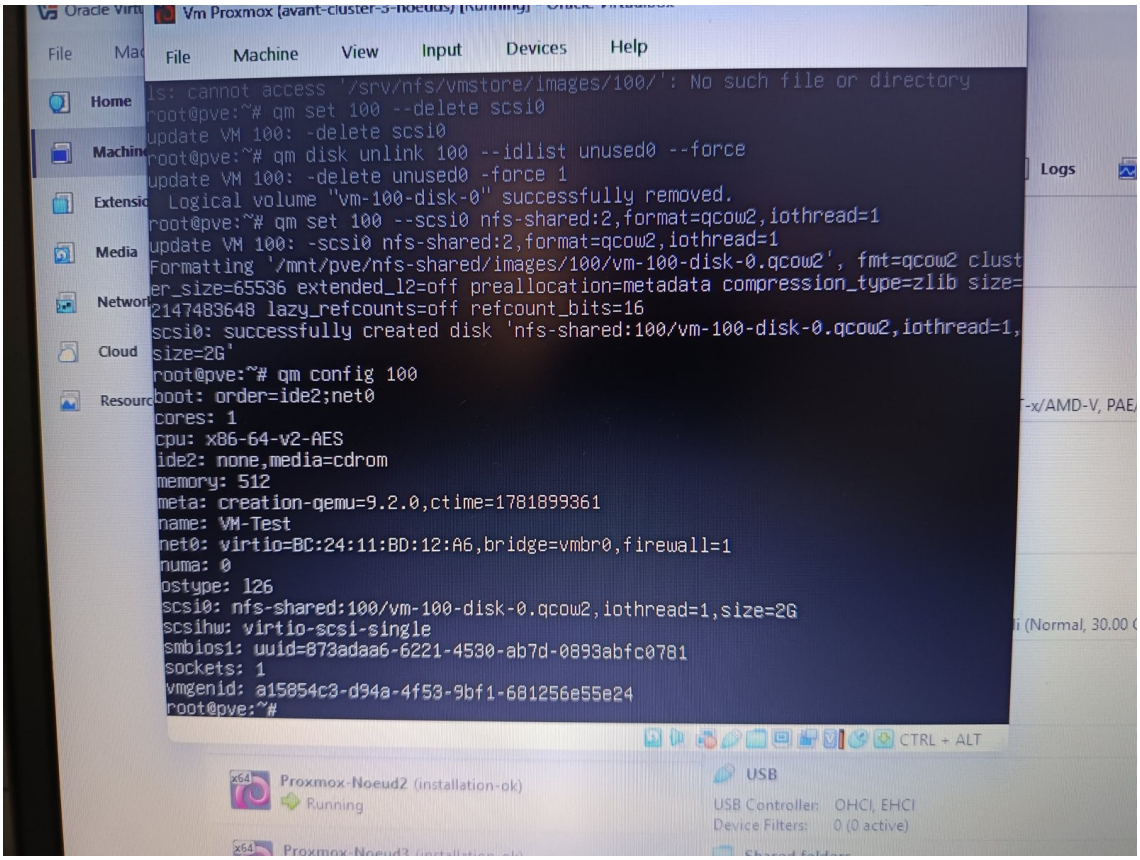


Plantage de la VM pve pendant la copie du disque (Guru Meditation)

La commande lvs a montré que le disque de VM-Test était vide (Data% = 0,00). Nous l'avons donc remplacé par un disque de 2 Go créé directement sur nfs-shared : qm set 100 --delete scsi0, qm disk unlink 100 --idlist unused0 --force, puis qm set 100 --scsi0 nfs-shared:2,format=qcow2,iothread=1. Résultat identique pour la suite du TP : le disque de la VM est sur le stockage partagé.

```
  vm-100-disk-0                          pve Vwi-a-tz--  32.00g data
                   0.00
  vm-102-disk-0                          pve Vwi-a-tz--  10.00g data snap_vm-102-d
isk-0_snap-apache-ok 20.44
  vm-102-state-snap-apache-ok            pve Vwi-a-tz--  <4.49g data
                   11.80
  vm-102-state-snap-exercices-s9         pve Vwi-a-tz--  <4.49g data
                   5.86
  vm-103-disk-0                          pve Vwi-a-tz--  10.00g data
                   20.18
  vm-104-disk-0                          pve Vwi-a-tz--   4.00g data
                   3.63
  vm-105-disk-0                          pve Vwi-a-tz--   8.00g data
                   2.60
  vm-106-disk-0                          pve Vwi-a-tz--   8.00g data
                   2.60
  vm-110-disk-0                          pve Vwi-a-tz--   2.00g data
                   19.69
  vm-110-disk-1                          pve Vwi-a-tz--   2.00g data
                   32.53
  vm-111-disk-0                          pve Vwi-a-tz--   2.00g data
                   29.52
  vm-112-disk-0                          pve Vwi-a-tz--   2.00g data
                   32.57
  vm-113-disk-0                          pve Vwi-a-tz--   2.00g data
                   32.58
  vm-114-disk-0                          pve Vwi-a-tz--   2.00g data
                   32.53
root@pve:~# _
```

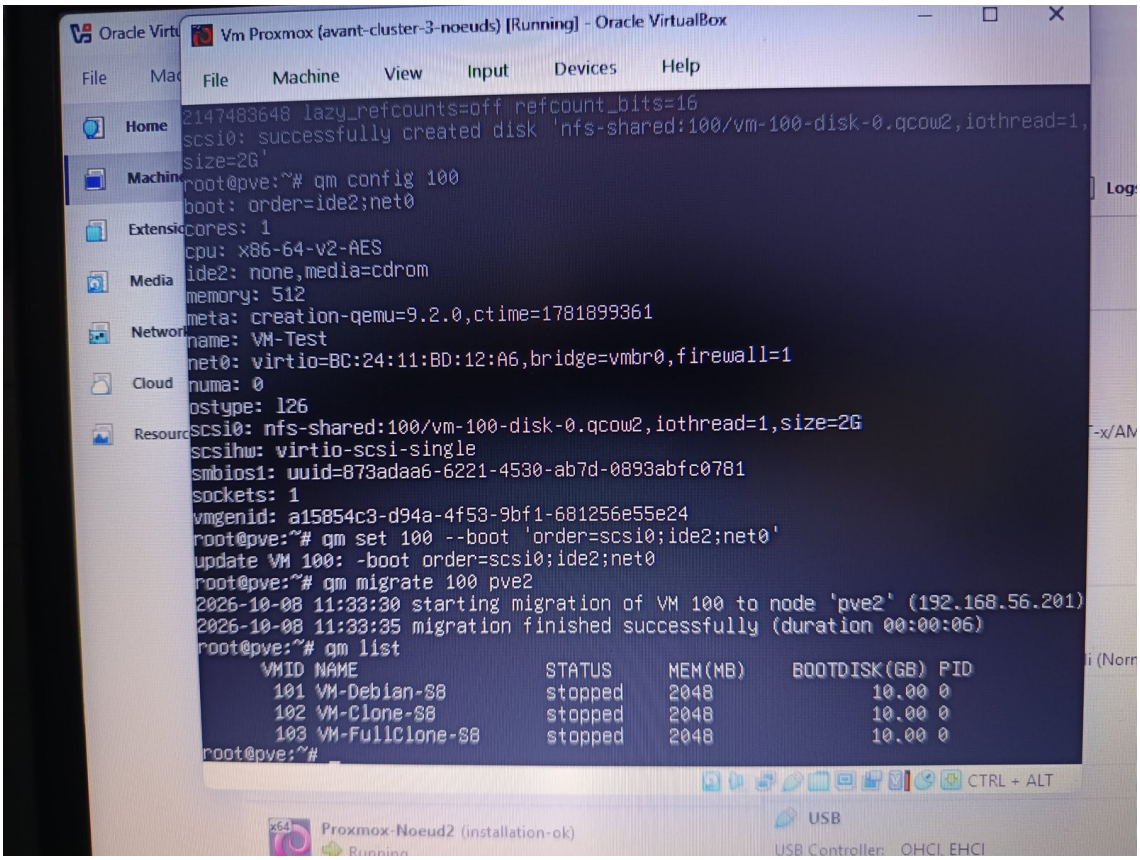
lvs : vm-100-disk-0 à 0,00 % (disque vide)



qm config 100 : scsi0: nfs-shared:100/vm-100-disk-0.qcow2, size=2G

3.5 — Migration de VM-Test vers pve2

Ordre de démarrage rétabli (qm set 100 --boot 'order=scsi0;ide2;net0'), puis qm migrate 100 pve2. La migration a duré 6 secondes : seule la configuration de la VM est déplacée, le disque reste sur nfs-shared et n'est pas copié.

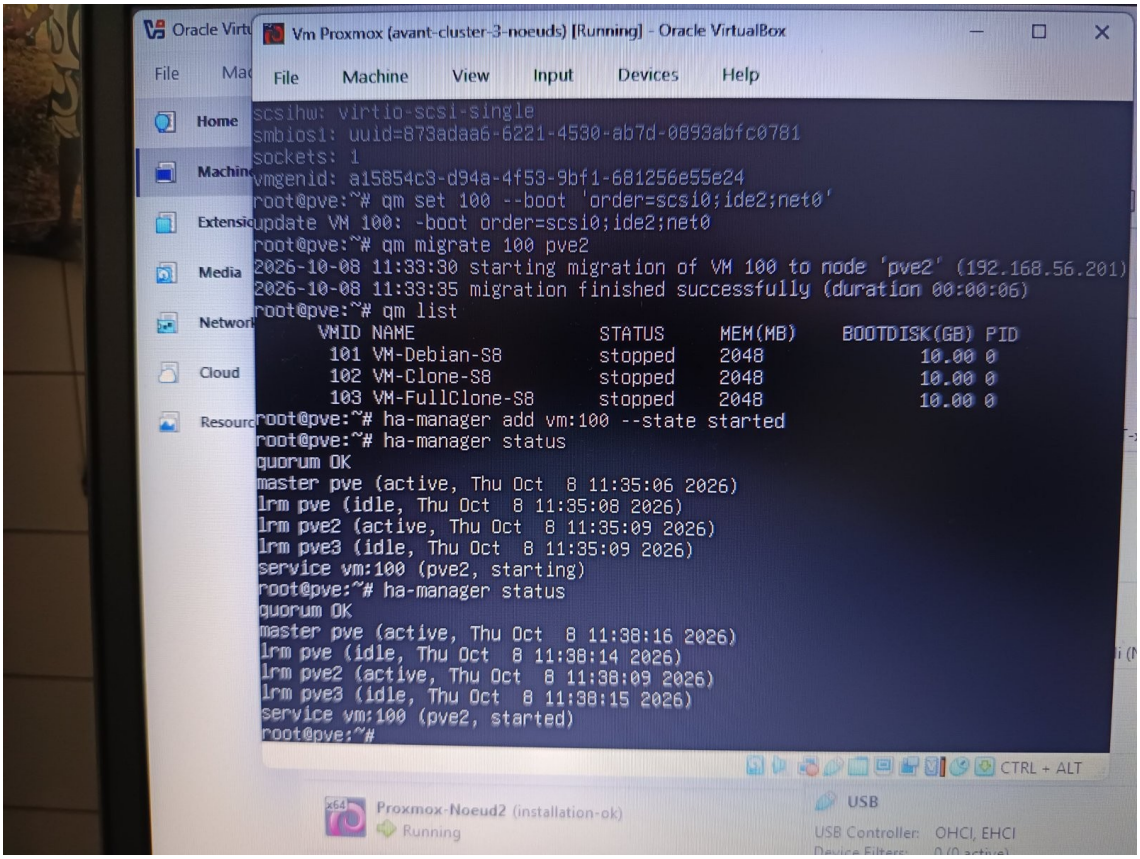


migration finished successfully (duration 00:00:06) ; VM 100 n'apparaît plus sur pve

PARTIE 4 — Haute disponibilité et test de panne

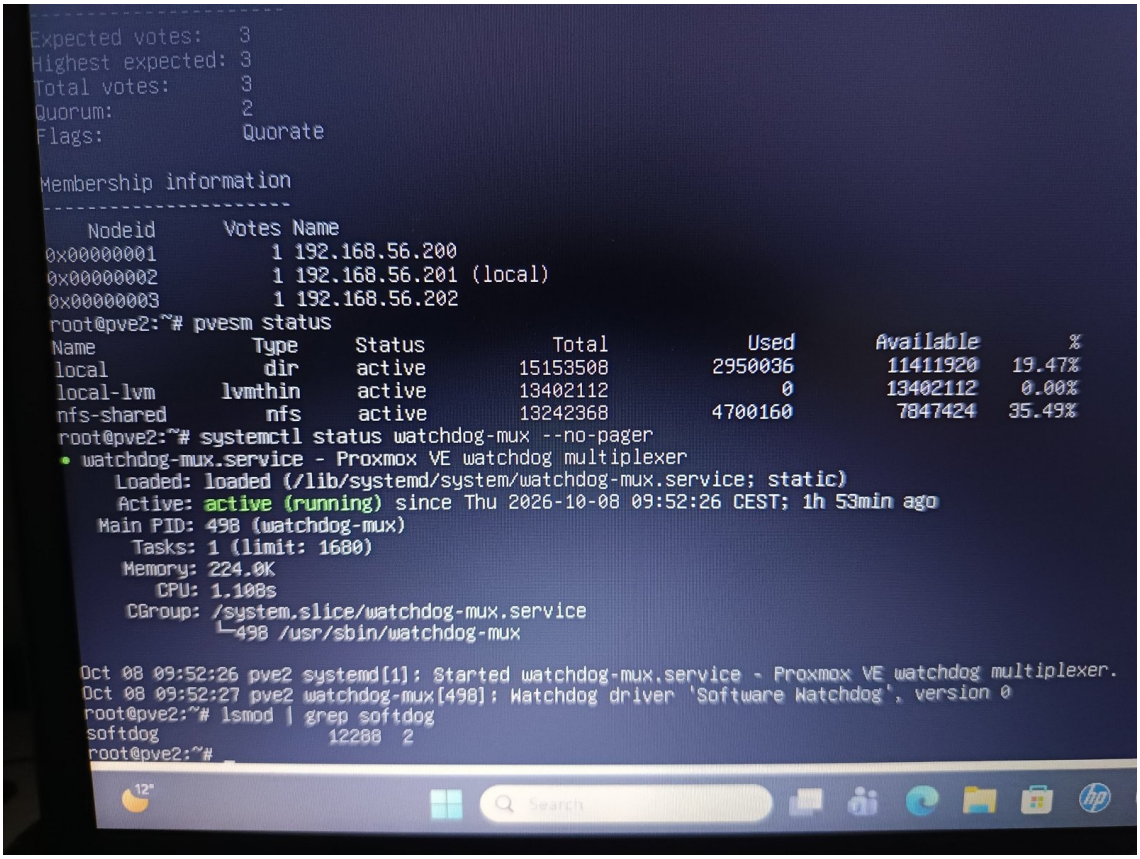
4.1 — Activation de la HA sur VM-Test

Commande : ha-manager add vm:100 --state started. La HA démarre la VM sur pve2.



ha-manager status : quorum OK, service vm:100 (pve2, started)

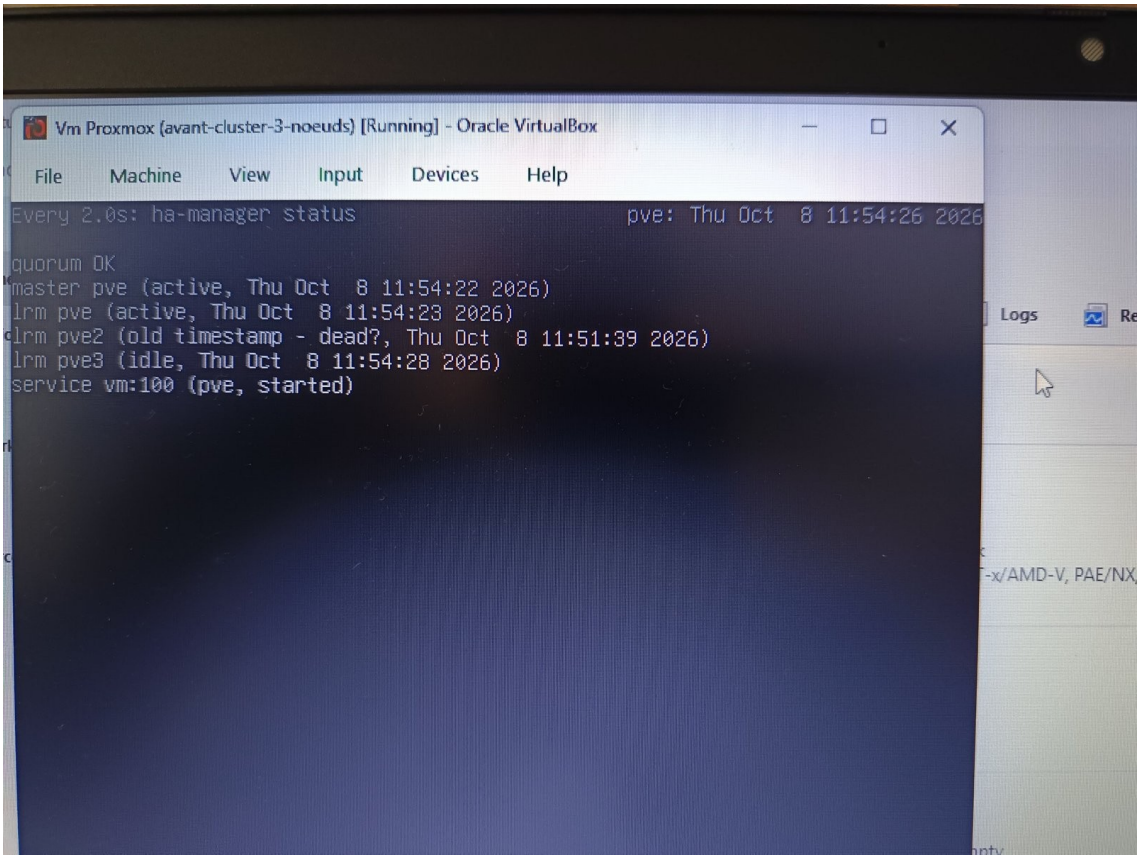
Mécanisme de surveillance sur le nœud hôte (pve2) : watchdog-mux est actif et utilise le « Software Watchdog » ; le module softdog est chargé. Si un nœud se fige, le watchdog le redémarre pour qu'il ne puisse pas continuer à faire tourner la VM pendant qu'elle est relancée ailleurs.



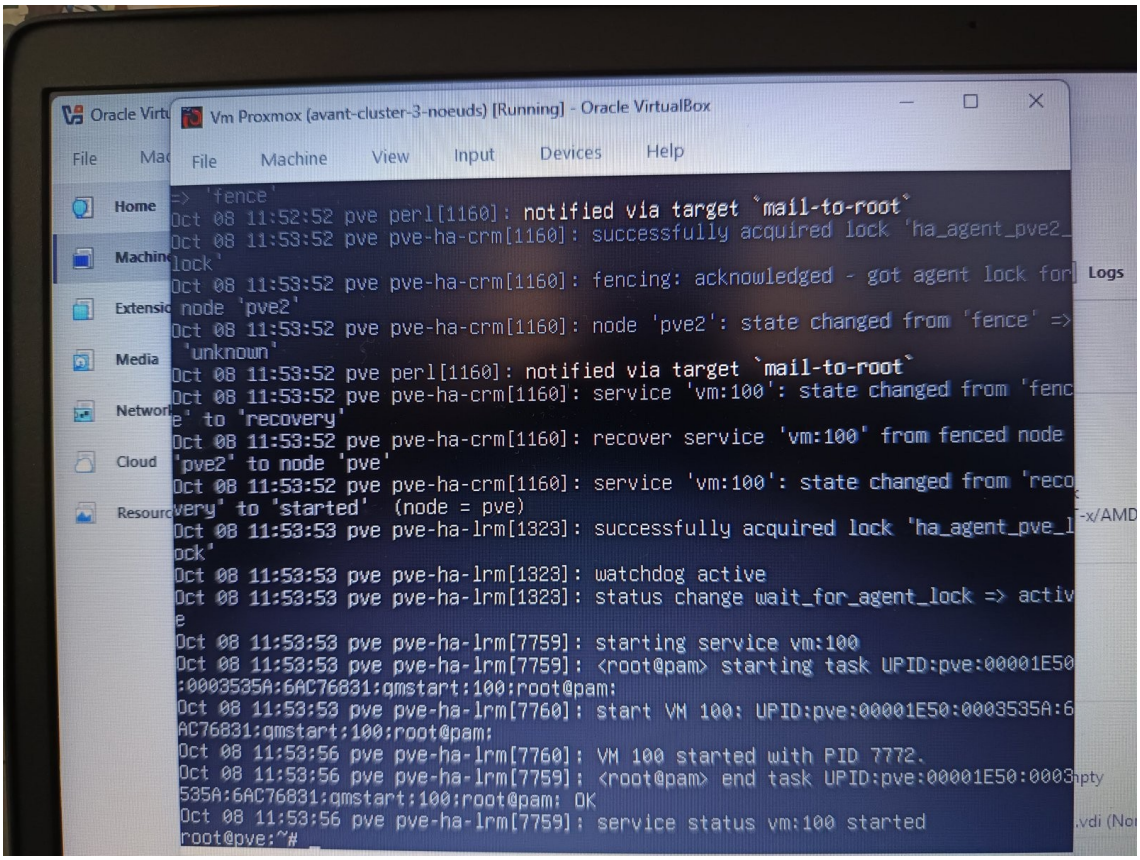
pve2 : watchdog-mux active (running), Software Watchdog, lsmod | grep softdog

4.2 — Test de panne et mesure du RTO

Arrêt brutal de pve2 dans VirtualBox (Machine > Fermer > Éteindre la machine). Les heures sont lues dans les journaux de la HA (journalctl -u pve-ha-crm -u pve-ha-lrm).



ha-manager status après la panne : pve2 « old timestamp - dead? », vm:100 (pve, started)



Journaux HA : fencing de pve2, recover service vm:100 vers pve, VM 100 started

Mesure	Valeur
t0 : arrêt du nœud (dernier signal de pve2)	11:51:39
t1 : service relancé (ha-manager)	11:53:52
t2 : VM de nouveau utilisable (VM 100 started)	11:53:56
RTO mesuré (t2 moins t0)	2 min 17 s
Calcul	11:53:56 − 11:51:39 = 2 min 17 s (137 s)
RTO cible (fixée par le groupe, voir ci-dessous)	15 min
Écart	15 min − 2 min 17 s = 12 min 43 s de marge : CONFORME

Preuves : t0 est lisible sur la capture ha-manager status (« lrm pve2 (old timestamp - dead?, … 11:51:39) ») ; t1 et t2 sont lisibles sur la capture du journal HA (« recover service 'vm:100' … 11:53:52 » et « VM 100 started … 11:53:56 »). Calcul vérifié à la main : de 11:51:39 à 11:53:39 = 2 min, puis + 17 s = 2 min 17 s.

Cible du CDC : notre CDC ne chiffre pas le RTO (« à confirmer avec le client »). Le groupe fixe donc la cible à 15 min pour la panne d'un nœud. Justification : la prise de rendez-vous en ligne est le service critique de Santélia ; la panne de mars l'a bloquée plus de 6 h ; une coupure de 15 min reste supportable pour les patients et l'accueil (prise de rendez-vous par téléphone pendant ce temps), et la HA relance la VM sans intervention de la DSI, qui ne compte que 2 personnes.

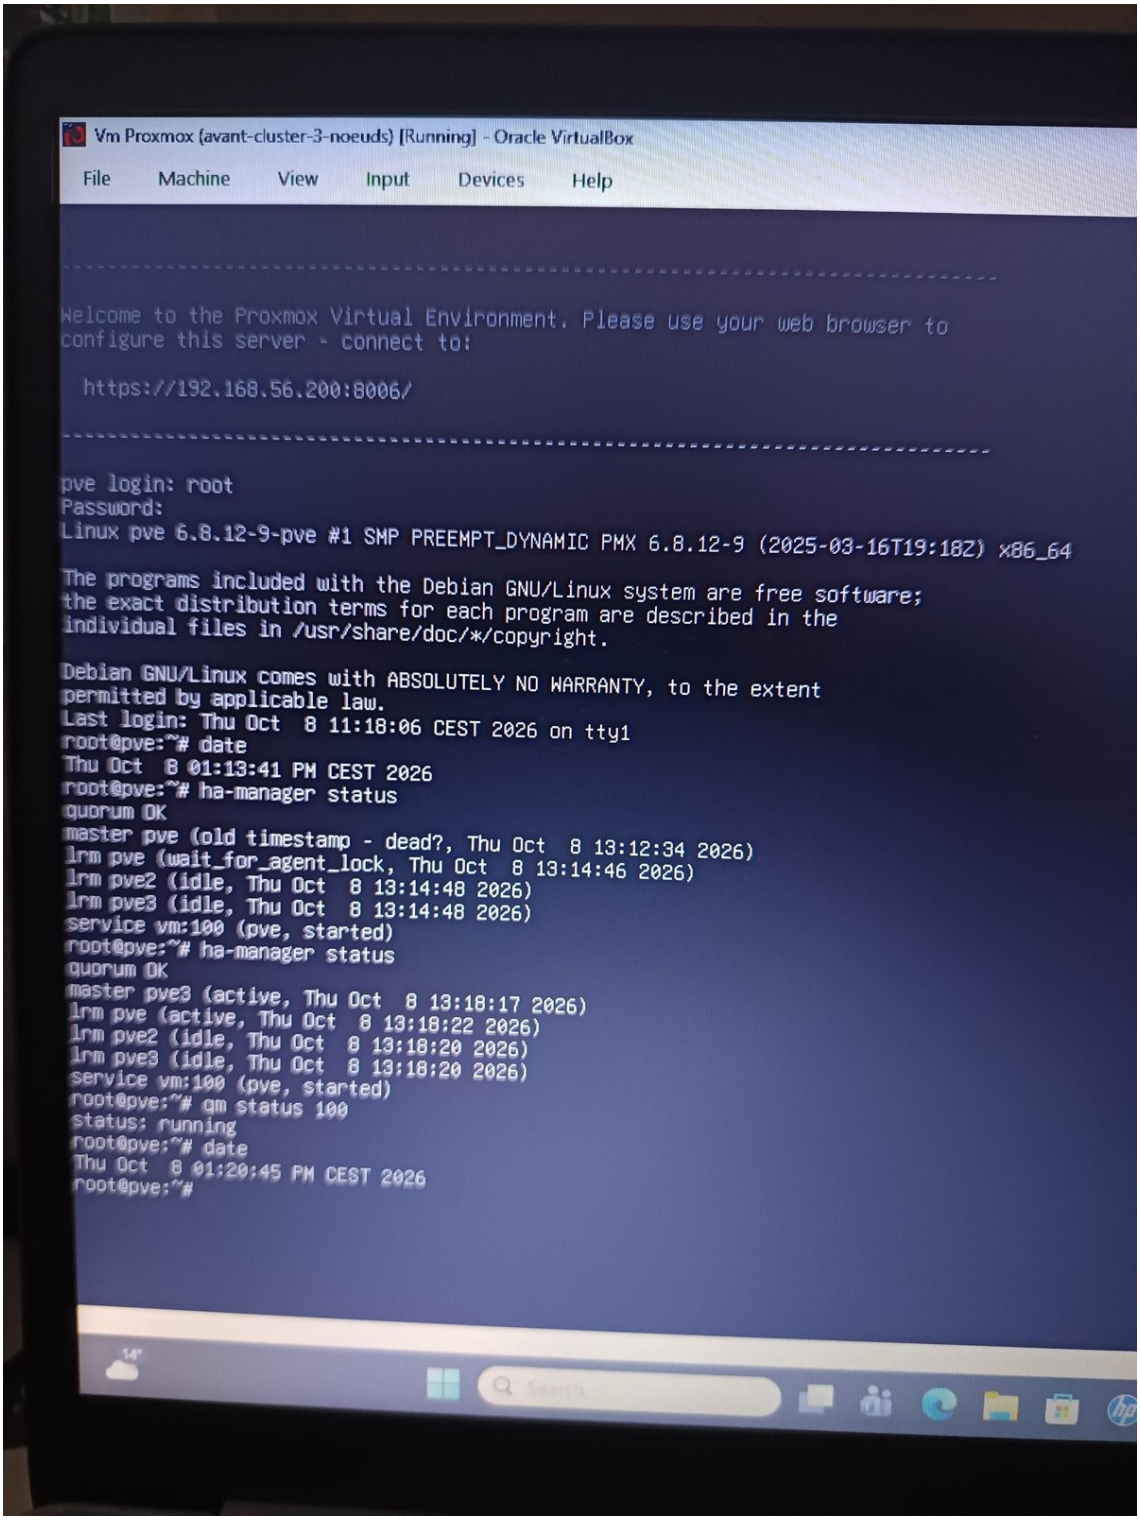
Analyse : presque tout le délai (environ 2 min 13 s) correspond à l'attente de sécurité pendant laquelle Proxmox s'assure que pve2 est vraiment arrêté (fencing) avant de relancer la VM. Le redémarrage lui-même a pris 4 secondes. La HA a choisi de relancer la VM sur pve (et non sur pve3) : c'est la HA qui choisit le nœud cible parmi les nœuds disponibles.

Limites : t0 est le dernier signal de pve2, quelques secondes avant l'arrêt réel. VM-Test n'a pas de système d'exploitation : « utilisable » signifie ici « VM démarrée ». Avec un vrai système, il faudrait ajouter son temps de démarrage (30 à 60 s environ).

Remise en état

pve2 a été rallumé et a rejoint le cluster (Nodes: 3, Quorate: Yes). La VM est restée sur pve : Proxmox ne remet pas automatiquement une VM sur son nœud d'origine (pas de « failback »), pour éviter une deuxième interruption.

Incident : après une mise en veille du PC hôte, les horloges de pve et pve3 avaient environ 36 min de retard (la HA a signalé « detected time drift »). La correction brutale de l'heure (chronyc makestep) a entraîné un redémarrage automatique de pve par son watchdog (auto-protection de la HA). La HA a ensuite tout remis en ordre seule : le rôle de maître est passé à pve3 et VM-Test est de nouveau running. Leçon : la synchronisation de l'heure (NTP) est indispensable dans un cluster.



État final : quorum OK, master pve3, vm:100 (pve, started), qm status 100 : running

Questions de compréhension

1. Pourquoi la VM ne peut-elle pas redémarrer ailleurs si son disque est stocké uniquement sur le nœud tombé ?

Le disque d'une VM est un fichier (ou un volume) qui contient tout son système et ses données. S'il est stocké sur le disque local du nœud tombé, les autres nœuds n'y ont pas accès : ils peuvent lire la configuration de la VM, mais pas son disque. Sans disque, la VM ne peut pas démarrer. C'est pour cela que nous avons placé le disque sur un stockage partagé (NFS), accessible par les 3 nœuds. Une autre solution est la réplication ZFS, qui copie régulièrement le disque sur les autres nœuds.

2. Quelle est la différence entre PCA et PRA sur le cas Santélia ?

Le PCA (Plan de Continuité d'Activité) sert à continuer le service pendant une panne, avec une coupure nulle ou très courte. Pour Santélia : si un serveur tombe, le cluster relance automatiquement le logiciel de rendez-vous ou de dossiers patients sur un autre serveur en quelques minutes (2 min 17 s dans notre test).

Le PRA (Plan de Reprise d'Activité) sert à redémarrer après un sinistre plus grave, quand le site entier ou les données sont touchés : incendie de la salle serveur, rançongiciel. On restaure alors à partir des sauvegardes (Proxmox Backup Server, copie hors site, règle 3-2-1). La reprise est plus longue (plusieurs heures) et on peut perdre les données depuis la dernière sauvegarde (RPO).

3. Votre RTO mesuré respecte-t-il l'exigence de votre CDC ? Sinon, que faudrait-il changer : la solution technique ou l'exigence ?

Notre CDC ne chiffrait pas le RTO ; le groupe a fixé la cible à 15 min pour la panne d'un nœud (justification ci-dessus, Partie 4.2). RTO mesuré : 2 min 17 s, soit 12 min 43 s de marge : la cible est respectée, il n'y a rien à changer. Si la direction exigeait une coupure de moins d'une minute, il faudrait changer la solution technique (applications en mode actif-actif, répartition de charge), car l'attente de sécurité (fencing) de la HA dure à elle seule environ 2 minutes.

Point d'amélioration : dans notre lab, le partage NFS est hébergé sur pve. Si pve tombe, le stockage partagé disparaît : c'est un point unique de défaillance. En production, il faudrait un stockage partagé lui-même redondant (NAS en haute disponibilité ou Ceph), et faire valider par le client un RTO et un RPO chiffrés.