TP HD/PCA — Construire le cluster Proxmox, le tester en cas de panne

GRETA de l'Essonne — Titre Professionnel AIS — Bloc 2 : Conception et évolution

Formateur : Samir KECHEMIR

Charles Maduba — Groupe 3 (travail réalisé en groupe de 4 stagiaires)

Séance A : lundi 5 octobre 2026 — Parties 1 et 2. Jeudi 8 octobre 2026 — Parties 3 et 4.

Synthèse de la séance

Partie	Contenu	État
1	Préparer 3 serveurs Proxmox (pve1, pve2, pve3)	Terminé
2	Créer le cluster et vérifier le quorum	Terminé
3	Stockage partagé (NFS)	Terminé
4	HA, test de panne, mesure du RTO	Terminé (RTO : 2 min 17 s, cible 15 min : conforme)

Nœud	Nom	Adresse IP
Nœud 1 (existant)	pve (alias pve1)	192.168.56.200
Nœud 2	pve2	192.168.56.201
Nœud 3	pve3	192.168.56.202

PARTIE 1 — Préparer les 3 serveurs

1.1 — Création de pve2 et pve3

Remarque : pve2 et pve3 n'ont pas été créés par clonage de pve1. Ils ont été installés à neuf à partir de l'ISO Proxmox VE, dans VirtualBox, sur le même réseau Host-Only 192.168.56.0/24. Il n'y a donc pas de captures de la fenêtre de clonage.

Conséquence : chaque nœud a eu dès l'installation ses propres clés SSH et son propre identifiant machine (machine-id). L'étape 1.3 (régénération des clés et du machine-id) n'a pas été nécessaire ; nous avons seulement vérifié que les trois identifiants sont bien différents.

1.2 — Nom, fichier /etc/hosts et adresse IP de chaque nœud

```
root@pve:~# cat /etc/hosts
127.0.0.1 localhost.localdomain localhost
192.168.56.200 pve.local.lan pve pve1
192.168.56.201 pve2.lab.local pve2
192.168.56.202 pve3.lab.local pve3

# The following lines are desirable for IPv6 capable hosts

::1     ip6-localhost ip6-loopback
fe00::0 ip6-localnet
ff00::0 ip6-mcastprefix
ff02::1 ip6-allnodes
ff02::2 ip6-allrouters
ff02::3 ip6-allhosts
root@pve:~# hostname -i
192.168.56.200
root@pve:~# cat /etc/machine-id
f4679ee0fbab48b2bebf6f1afdb5e526
root@pve:~#
```

pve1 : /etc/hosts avec les 3 nœuds, hostname -i = 192.168.56.200, machine-id

```
root@pve2:~# cat /etc/hosts
127.0.0.1 localhost.localdomain localhost
192.168.56.201 pve2.lab.local pve2
192.168.56.200 pve.local.lan pve pve1
192.168.56.202 pve3.lab.local pve3

# The following lines are desirable for IPv6 capable hosts

::1     ip6-localhost ip6-loopback
fe00::0 ip6-localnet
ff00::0 ip6-mcastprefix
ff02::1 ip6-allnodes
ff02::2 ip6-allrouters
ff02::3 ip6-allhosts
root@pve2:~# hostname -i
192.168.56.201
root@pve2:~# ip -br a
lo               UNKNOWN        127.0.0.1/8 ::1/128
enp0s3           UP
enp0s8           UP             10.0.3.15/24 fd17:625c:f037:3:a00:27ff:feef:ef90/64 fe80::a00:27ff:feef:ef90/64
vmbr0            UP             192.168.56.201/24 fe80::a00:27ff:fef6:a204/64
root@pve2:~#
```

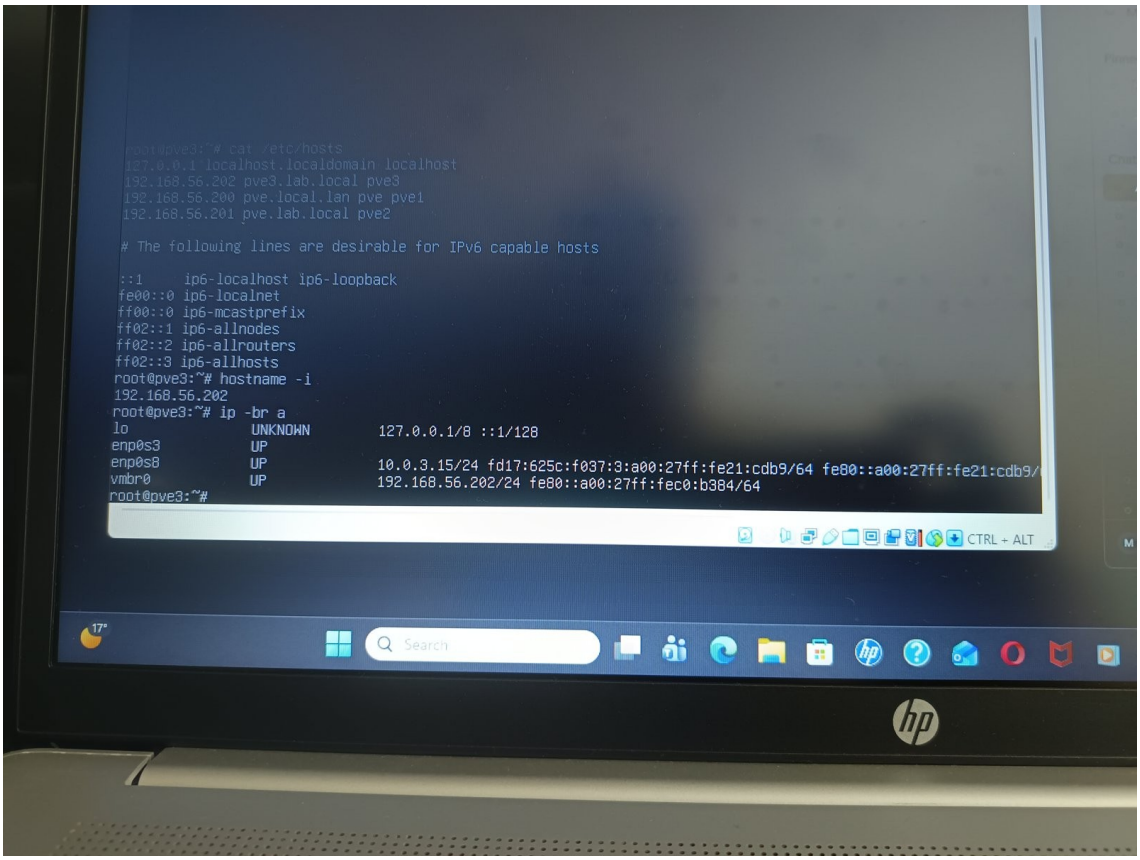
pve2 : /etc/hosts, hostname -i et ip -br a (vmbr0 = 192.168.56.201)

```
root@pve3:~# sed -i 's/201 pve.lab.local/201 pve2.lab.local/' /etc/hosts
root@pve3:~# cat /etc/hosts
127.0.0.1 localhost.localdomain localhost
192.168.56.202 pve3.lab.local pve3
192.168.56.200 pve.local.lan pve pve1
192.168.56.201 pve2.lab.local pve2

# The following lines are desirable for IPv6 capable hosts

::1     ip6-localhost ip6-loopback
fe00::0 ip6-localnet
ff00::0 ip6-mcastprefix
ff02::1 ip6-allnodes
ff02::2 ip6-allrouters
ff02::3 ip6-allhosts
root@pve3:~#
```

pve3 : contenu de /etc/hosts



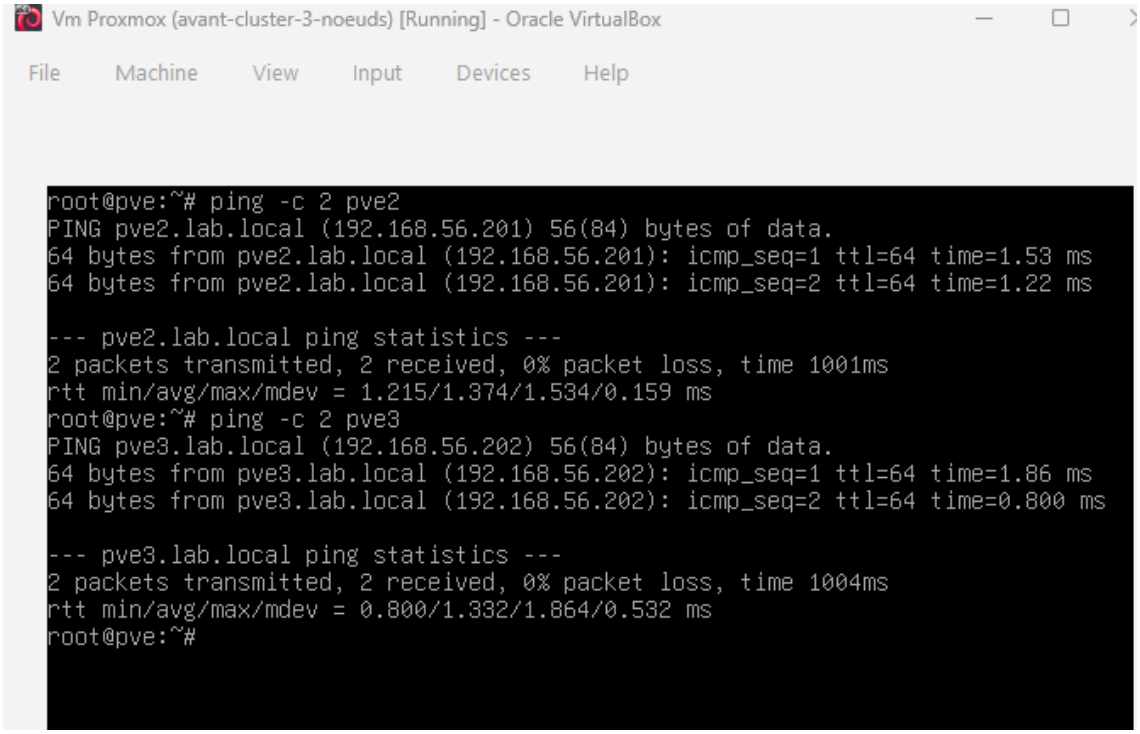
pve3 : hostname -i et ip -br a (vmbr0 = 192.168.56.202)

1.3 — Les 3 machine-id

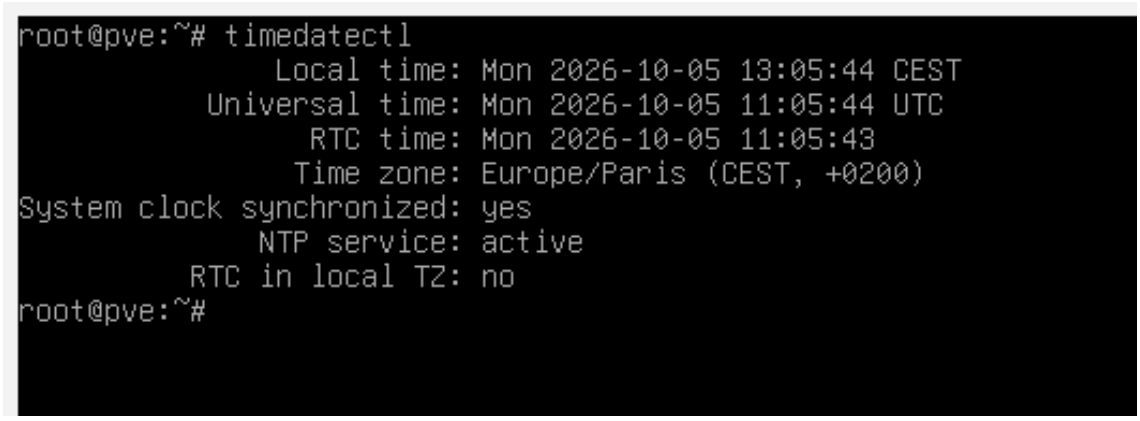
Nœud	machine-id
pve1	f4679ee0fbab48b2bebf6f1afdb5e526
pve2	0c5c5b5745d04cf2985687e8c53da75f
pve3	c895ad2836d5419fb7c48d0328d078e3

Les trois identifiants sont différents (captures ci-dessus pour pve1, ci-dessous pour pve2 et pve3).

1.4 — Les 3 nœuds se voient (ping, heure, nœuds vides)



pve1 : ping -c 2 pve2 et ping -c 2 pve3 — réponse avec la bonne adresse IP



pve1 : timedatectl — System clock synchronized: yes

```
root@pve2:~# cat /etc/machine-id
0c5c5b5745d04cf2985687e8c53da75f
root@pve2:~# ping -c 2 pve1
PING pve.local.lan (192.168.56.200) 56(84) bytes of data.
64 bytes from pve.local.lan (192.168.56.200): icmp_seq=1 ttl=64 time=1.33 ms
64 bytes from pve.local.lan (192.168.56.200): icmp_seq=2 ttl=64 time=0.620 ms

--- pve.local.lan ping statistics ---
2 packets transmitted, 2 received, 0% packet loss, time 1003ms
rtt min/avg/max/mdev = 0.620/0.974/1.329/0.354 ms
root@pve2:~# ping -c 2 pve3
PING pve3.lab.local (192.168.56.202) 56(84) bytes of data.
64 bytes from pve3.lab.local (192.168.56.202): icmp_seq=1 ttl=64 time=5.83 ms
64 bytes from pve3.lab.local (192.168.56.202): icmp_seq=2 ttl=64 time=0.584 ms

--- pve3.lab.local ping statistics ---
2 packets transmitted, 2 received, 0% packet loss, time 1107ms
rtt min/avg/max/mdev = 0.584/3.207/5.831/2.623 ms
root@pve2:~# timedatectl
               Local time: Mon 2026-10-05 12:42:18 CEST
           Universal time: Mon 2026-10-05 10:42:18 UTC
                 RTC time: Mon 2026-10-05 10:42:18
                Time zone: Europe/Paris (CEST, +0200)
System clock synchronized: yes
              NTP service: active
          RTC in local TZ: no
root@pve2:~# qm list
root@pve2:~# pct list
root@pve2:~#
```

pve2 : machine-id, ping pve1 et pve3, timedatectl (synchronisé), qm list et pct list vides

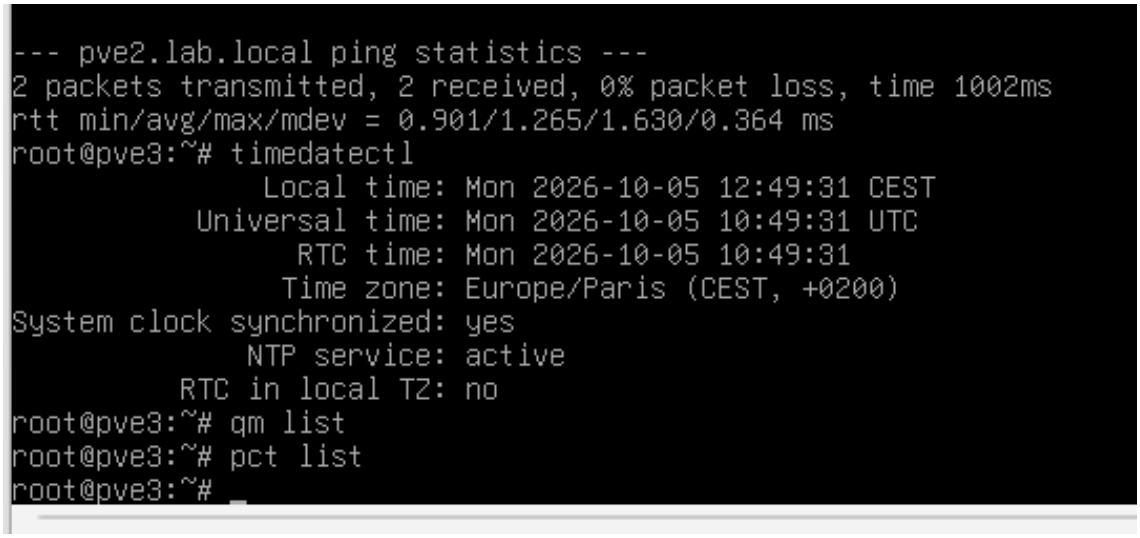
```
192.168.56.202
root@pve3:~# ip -br a
lo               UNKNOWN        127.0.0.1/8 ::1/128
enp0s3           UP
enp0s8           UP             10.0.3.15/24 fd17:625c:f037:3:a00:27ff:fe21:cdb9/64 fe80::a00:27ff:fe21:cdb9
vmbr0            UP             192.168.56.202/24 fe80::a00:27ff:fec0:b384/64
root@pve3:~# sed -i 's/201 pve.lab.local/201 pve2.lab.local/' /etc/hosts
root@pve3:~# cat /etc/hosts
127.0.0.1 localhost.localdomain localhost
192.168.56.202 pve3.lab.local pve3
192.168.56.200 pve.local.lan pve pve1
192.168.56.201 pve2.lab.local pve2

# The following lines are desirable for IPv6 capable hosts

::1     ip6-localhost ip6-loopback
fe00::0 ip6-localnet
ff00::0 ip6-mcastprefix
ff02::1 ip6-allnodes
ff02::2 ip6-allrouters
ff02::3 ip6-allhosts
root@pve3:~# cat /etc/machine-id
c895ad2836d5419fb7c48d0328d078e3
root@pve3:~# ping -c 2 pve1
PING pve.local.lan (192.168.56.200) 56(84) bytes of data.
64 bytes from pve.local.lan (192.168.56.200): icmp_seq=1 ttl=64 time=2.37 ms
64 bytes from pve.local.lan (192.168.56.200): icmp_seq=2 ttl=64 time=0.647 ms

--- pve.local.lan ping statistics ---
2 packets transmitted, 2 received, 0% packet loss, time 1002ms
rtt min/avg/max/mdev = 0.647/1.508/2.370/0.861 ms
root@pve3:~# ping -c 2 pve2
PING pve2.lab.local (192.168.56.201) 56(84) bytes of data.
64 bytes from pve2.lab.local (192.168.56.201): icmp_seq=1 ttl=64 time=1.63 ms
64 bytes from pve2.lab.local (192.168.56.201): icmp_seq=2 ttl=64 time=0.901 ms
```

pve3 : ip -br a, /etc/hosts, machine-id, ping pve1 et pve2

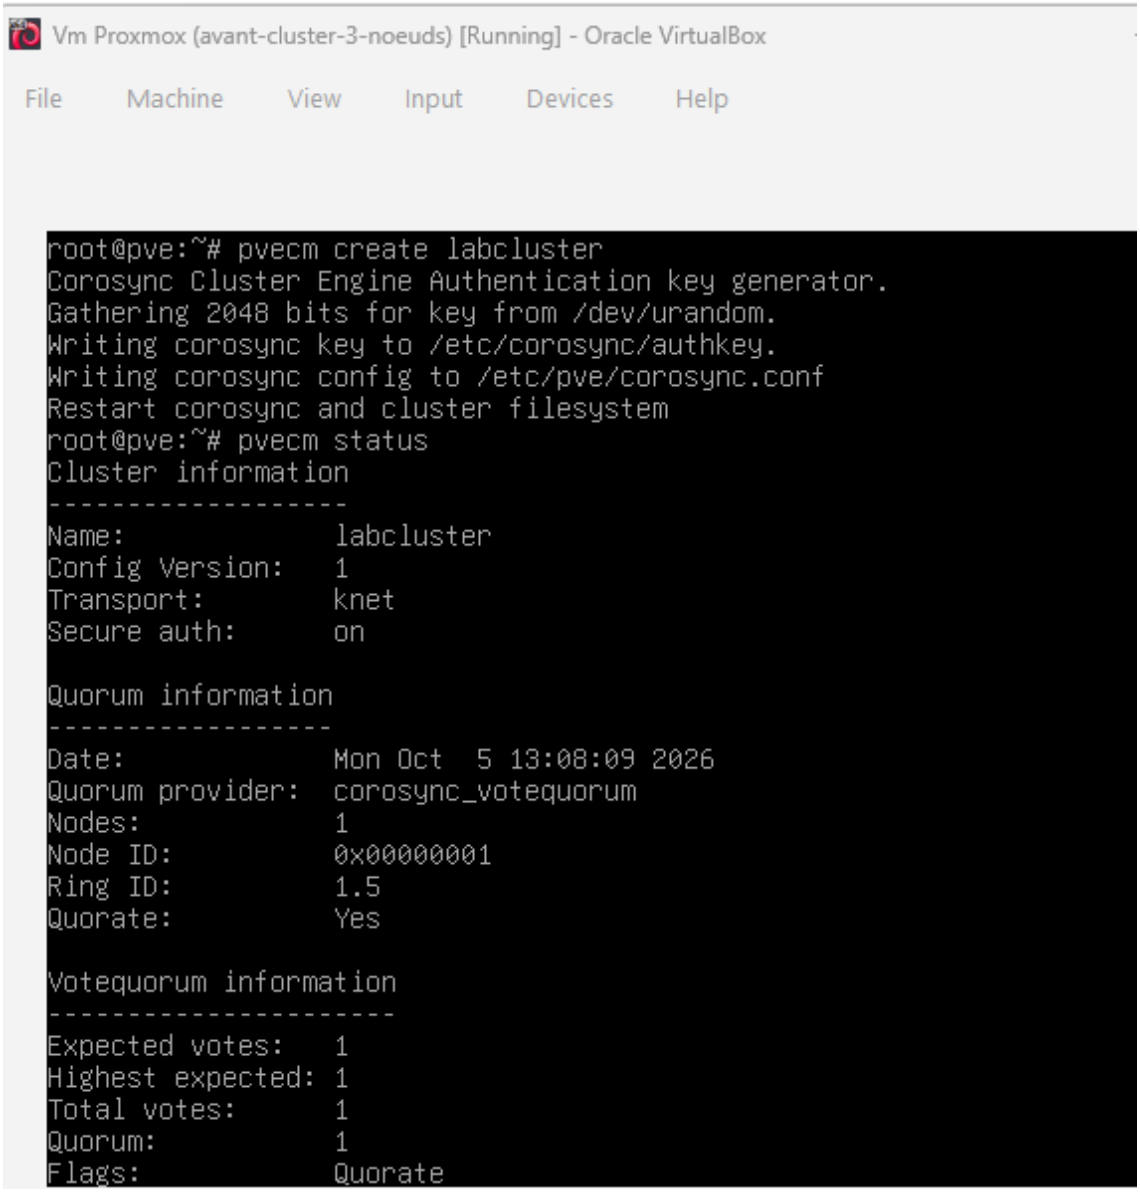


pve3 : timedatectl (synchronisé), qm list et pct list vides

Résultat : chaque nom répond avec la bonne adresse IP, l'horloge est synchronisée sur les 3 nœuds, et pve2 et pve3 ne contiennent aucune VM ni aucun conteneur (condition pour rejoindre le cluster).

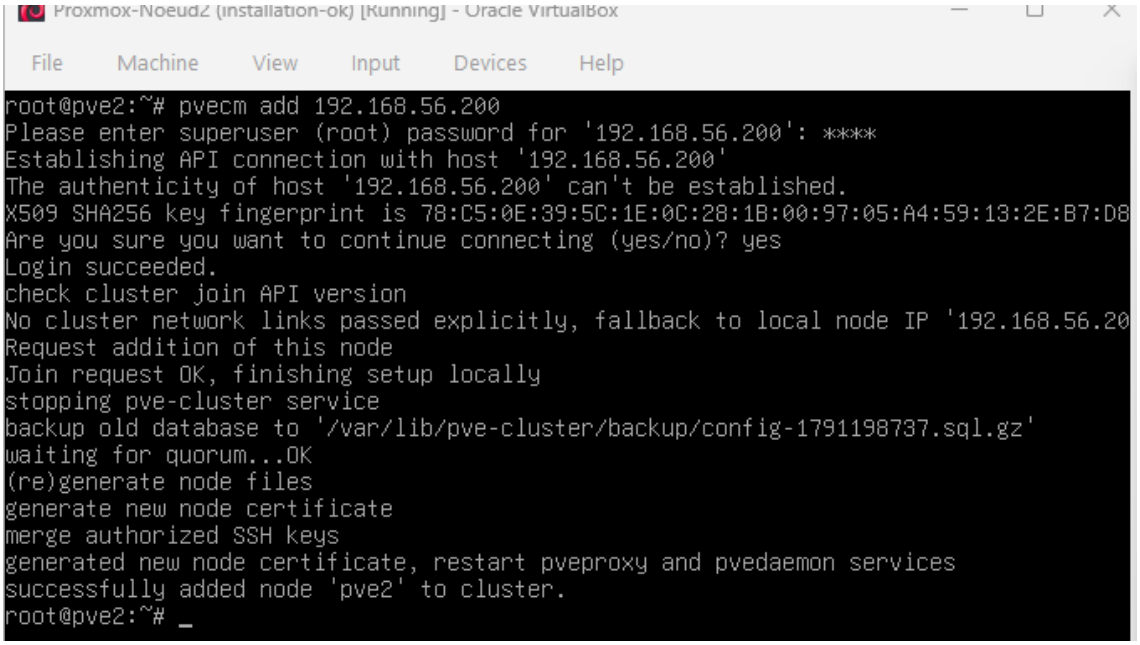
PARTIE 2 — Créer le cluster

2.1 / 2.2 — Création du cluster sur pve1 et premier pvecm status



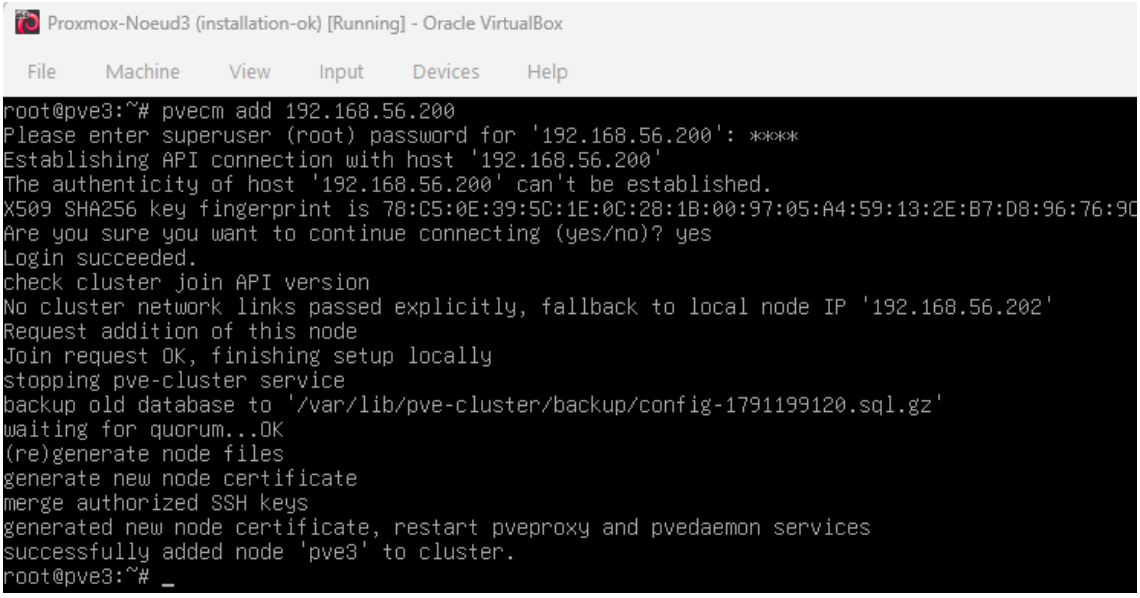
pvecm create labcluster puis pvecm status : Nodes: 1, Quorate: Yes

2.3 — Ajout de pve2



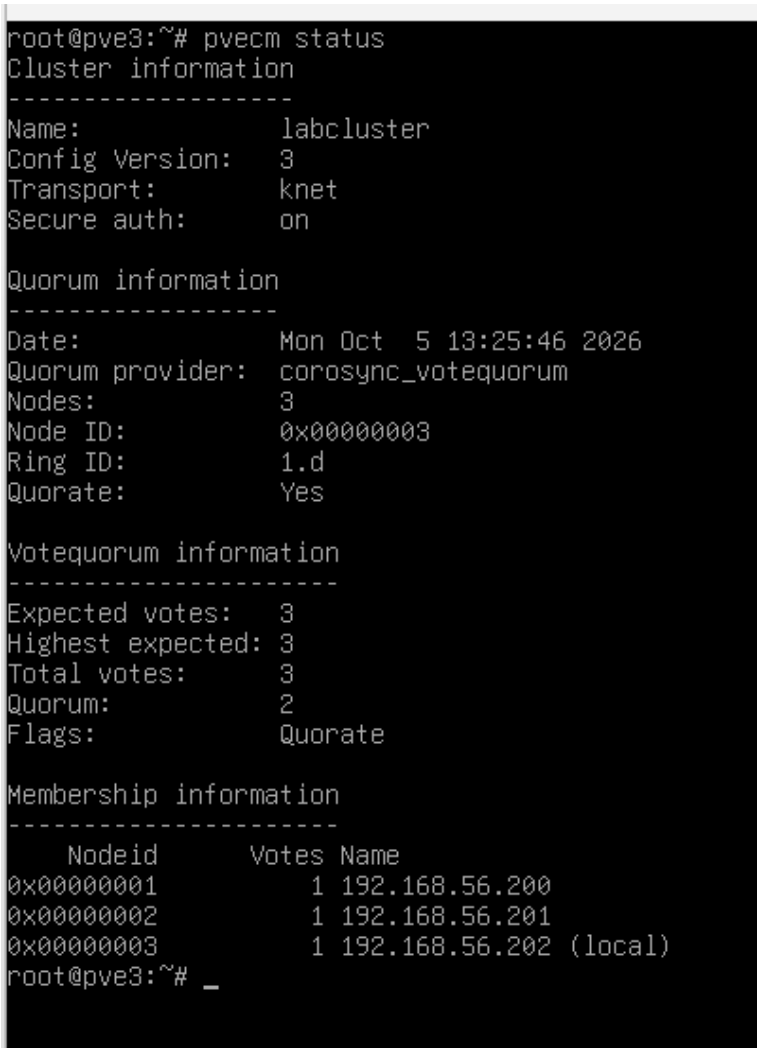
pve2 : pvecm add 192.168.56.200 — nœud ajouté au cluster

2.4 — Ajout de pve3



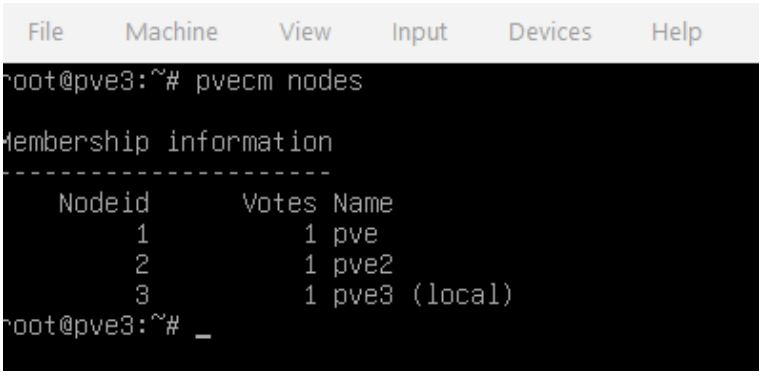
pve3 : pvecm add 192.168.56.200 — nœud ajouté au cluster

2.5 — pvecm status avec les 3 nœuds



Nodes: 3, Total votes: 3, Quorum: 2, Quorate: Yes

2.6 — pvecm nodes



pve, pve2 et pve3 listés

2.7 — Expérience : le quorum en direct

Situation	Votes présents	Quorate	Observation

3 nœuds allumés	3 / 3	Yes	Cluster normal
pve3 éteint	2 / 3	Yes	Le cluster continue de fonctionner
pve2 et pve3 éteints	1 / 3	No	« Activity blocked » : le cluster refuse d'agir
pve2 et pve3 rallumés	3 / 3	Yes	Retour à la normale après 1 à 2 minutes

```
root@pve:~# pvecm status
Cluster information
-------------------
Name:             labcluster
Config Version:   3
Transport:        knet
Secure auth:      on

Quorum information
------------------
Date:             Mon Oct  5 13:29:31 2026
Quorum provider:  corosync_votequorum
Nodes:            2
Node ID:          0x00000001
Ring ID:          1.11
Quorate:          Yes

Votequorum information
----------------------
Expected votes:   3
Highest expected: 3
Total votes:      2
Quorum:           2
Flags:            Quorate

Membership information
----------------------
    Nodeid      Votes Name
0x00000001          1 192.168.56.200 (local)
0x00000002          1 192.168.56.201
```

pve3 éteint : Nodes: 2, Quorate: Yes

```
root@pve:~# pvecm status
Cluster information
-------------------
Name:             labcluster
Config Version:   3
Transport:        knet
Secure auth:      on

Quorum information
------------------
Date:             Mon Oct  5 13:32:30 2026
Quorum provider:  corosync_votequorum
Nodes:            1
Node ID:          0x00000001
Ring ID:          1.15
Quorate:          No

Votequorum information
----------------------
Expected votes:   3
Highest expected: 3
Total votes:      1
Quorum:           2 Activity blocked
Flags:

Membership information
----------------------
    Nodeid      Votes Name
0x00000001          1 192.168.56.200 (local)
root@pve:~# _
```

pve2 et pve3 éteints : Nodes: 1, Quorate: No, « Activity blocked »

```
root@pve:~# pvecm status
Cluster information
-------------------
Name:             labcluster
Config Version:   3
Transport:        knet
Secure auth:      on

Quorum information
------------------
Date:             Mon Oct  5 13:44:12 2026
Quorum provider:  corosync_votequorum
Nodes:            3
Node ID:          0x00000001
Ring ID:          1.1e
Quorate:          Yes

Votequorum information
----------------------
Expected votes:   3
Highest expected: 3
Total votes:      3
Quorum:           2
Flags:            Quorate

Membership information
----------------------
    Nodeid      Votes Name
0x00000001          1 192.168.56.200 (local)
0x00000002          1 192.168.56.201
```

pve2 et pve3 rallumés : Nodes: 3, Quorate: Yes

Question : pourquoi 2 nœuds sur 3 suffisent, alors que 1 nœud sur 3 ne suffit pas ?

Le quorum est la majorité des votes : quorum = (nombre de nœuds ÷ 2) arrondi à l'inférieur + 1. Avec 3 nœuds : 3 ÷ 2 = 1,5 → 1, puis 1 + 1 = 2 votes.

Avec 2 nœuds allumés, on a 2 votes ≥ 2 : le cluster a le quorum et continue de fonctionner.

Avec 1 seul nœud, on a 1 vote < 2 : pas de quorum, le cluster bloque les actions (« Activity blocked »). C'est la protection contre le split-brain : un nœud isolé ne doit pas agir seul, car il ne sait pas si les autres fonctionnent encore de leur côté. S'il le faisait, deux parties du cluster pourraient démarrer la même VM en même temps et abîmer ses données.

PARTIE 3 — Stockage partagé (NFS)

Réalisée en ligne de commande (pvesm / qm) plutôt que dans l'interface web : avec les 3 nœuds allumés, le PC hôte n'avait pas assez de mémoire pour ouvrir un navigateur. Le résultat est identique, l'interface web utilise les mêmes commandes.

3.1 — Installation du serveur NFS sur pve et création du dossier partagé

Commandes : apt install -y nfs-kernel-server puis mkdir -p /srv/nfs/vmstore. Avant l'installation, nous avons vérifié l'accès Internet de pve (ping deb.debian.org : 0 % de perte).

```
Reading package lists... Done
Building dependency tree... Done
Reading state information... Done
The following NEW packages will be installed:
  nfs-kernel-server
0 upgraded, 1 newly installed, 0 to remove and 149 not upgraded.
Need to get 152 kB of archives.
After this operation, 626 kB of additional disk space will be used.
Get:1 http://ftp.fr.debian.org/debian bookworm/main amd64 nfs-kernel-server amd6
4 1:2.6.2-4+deb12u1 [152 kB]
Fetched 152 kB in 0s (1,569 kB/s)
Selecting previously unselected package nfs-kernel-server.
(Reading database ... 46310 files and directories currently installed.)
Preparing to unpack .../nfs-kernel-server_1%3a2.6.2-4+deb12u1_amd64.deb ...
Unpacking nfs-kernel-server (1:2.6.2-4+deb12u1) ...
Setting up nfs-kernel-server (1:2.6.2-4+deb12u1) ...
Created symlink /etc/systemd/system/nfs-client.target.wants/nfs-blkmap.service →
 /lib/systemd/system/nfs-blkmap.service.
Created symlink /etc/systemd/system/multi-user.target.wants/nfs-server.service →
 /lib/systemd/system/nfs-server.service.
nfs-mountd.service is a disabled or a static unit, not starting it.
nfsdcld.service is a disabled or a static unit, not starting it.

Creating config file /etc/exports with new version

Creating config file /etc/default/nfs-kernel-server with new version
Processing triggers for man-db (2.11.2-2) ...
root@pve:~# mkdir -p /srv/nfs/vmstore
root@pve:~#
```

Installation de nfs-kernel-server sans erreur, création de /srv/nfs/vmstore

3.2 — Déclaration du partage (exportfs -v)

Ligne ajoutée dans /etc/exports : /srv/nfs/vmstore 192.168.56.0/24(rw,sync,no_subtree_check,no_root_squash), puis exportfs -ra. Seul le réseau du lab (192.168.56.0/24) peut accéder au partage.

```
root@pve:~# mkdir -p /srv/nfs/vmstore
root@pve:~# echo '/srv/nfs/vmstore 192.168.56.0/24(rw,sync,no_subtree_check,no_r
oot_squash)' >> /etc/exports
root@pve:~# cat /etc/exports
# /etc/exports: the access control list for filesystems which may be exported
#               to NFS clients.  See exports(5).
#
# Example for NFSv2 and NFSv3:
# /srv/homes       hostname1(rw,sync,no_subtree_check) hostname2(ro,sync,no_subt
ree_check)
#
# Example for NFSv4:
# /srv/nfs4        gss/krb5i(rw,sync,fsid=0,crossmnt,no_subtree_check)
# /srv/nfs4/homes  gss/krb5i(rw,sync,no_subtree_check)
#
/srv/nfs/vmstore 192.168.56.0/24(rw,sync,no_subtree_check,no_root_squash)
root@pve:~# exportfs-ra
-bash: exportfs-ra: command not found
root@pve:~# exportfs -ra
root@pve:~# exportfs -v
/srv/nfs/vmstore
                192.168.56.0/24(sync,wdelay,hide,no_subtree_check,sec=sys,rw,sec
ure,no_root_squash,no_all_squash)
root@pve:~#
```

cat /etc/exports et exportfs -v : le partage /srv/nfs/vmstore est actif

3.3 — Stockage nfs-shared ajouté au cluster (visible sur les 3 nœuds)

Commande sur pve : pvesm add nfs nfs-shared --server 192.168.56.200 --export /srv/nfs/vmstore --content images. Le stockage est défini au niveau du Datacenter : pve2 et pve3 le reçoivent automatiquement.

```
root@pve:~# systemctl restart pve-cluster
root@pve:~# pvesm add nfs nfs-shared --server 192.168.56.200 --export /srv/nfs/v
mstore --content images
root@pve:~# pvesm status
Name             Type     Status           Total            Used       Availabl
e        %
local             dir     active        13242248         4698152         784962
0   35.48%
local-lvm     lvmthin     active        11460608         9796527         166408
0   85.48%
nfs-shared        nfs     active        13242368         4698112         784998
4   35.48%
root@pve:~#
```

pve : nfs-shared de type nfs, statut active

```
root@pve2:~# pvesm status
Name             Type     Status           Total            Used       Available        %
local             dir     active        15153508         2950036        11411920   19.47%
local-lvm     lvmthin     active        13402112               0        13402112    0.00%
nfs-shared        nfs     active        13242368         4700160         7847424   35.49%
root@pve2:~#
```

pve2 : nfs-shared actif

```
root@pve3:~# pvesm status
Name             Type     Status           Total            Used       Available        %
local             dir     active        15153508         2941592        11420364   19.41%
local-lvm     lvmthin     active        13402112               0        13402112    0.00%
nfs-shared        nfs     active        13242368         4700160         7847424   35.49%
root@pve3:~# _
```

pve3 : nfs-shared actif

Remarque : une première tentative a échoué avec « cfs-lock … error: no quorum » alors que pvecm status indiquait Quorate: Yes. Le service de configuration du cluster (pmxcfs) était resté en lecture seule après une perte de contact entre les nœuds. Résolu par systemctl restart pve-cluster.

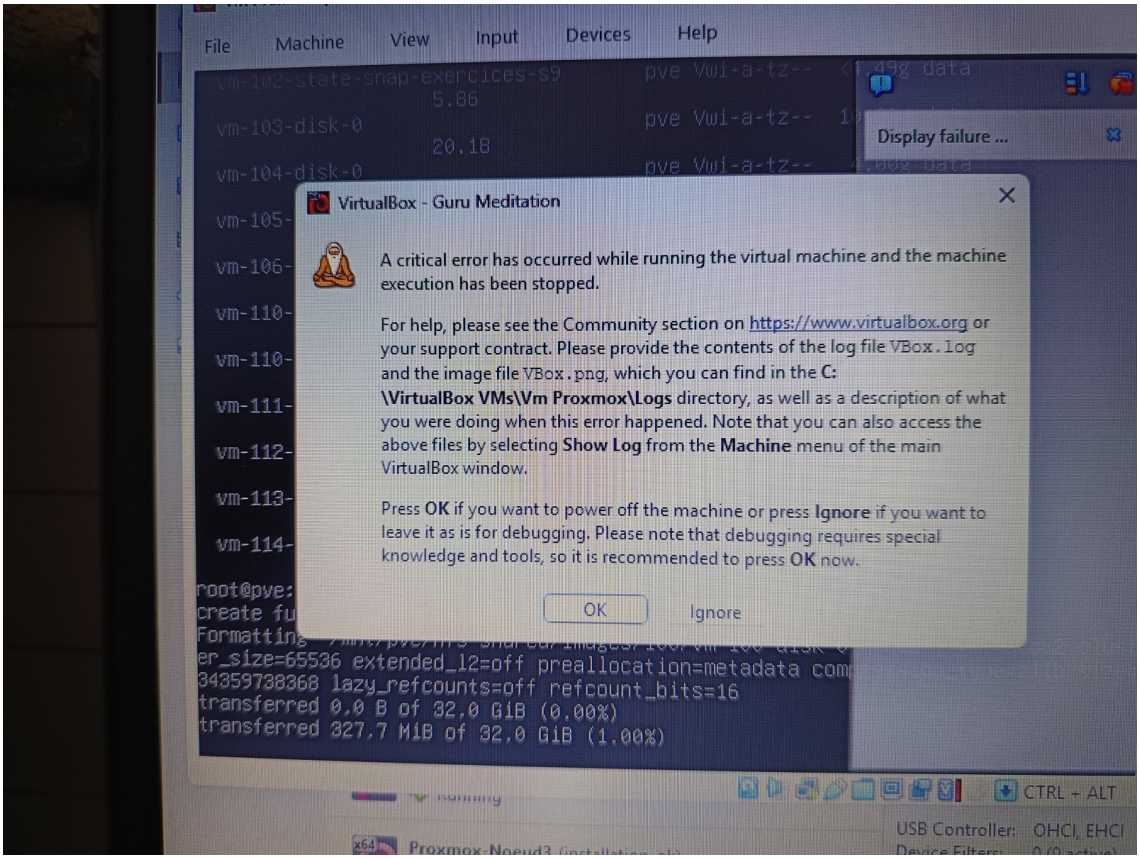
3.4 — Disque de VM-Test placé sur nfs-shared

VM-Test est la VM 100 (512 Mo de RAM, pas d'ISO dans le lecteur CD). Son disque de 32 Go était sur local-lvm.

```
root@pve:~# qm list
      VMID NAME                 STATUS     MEM(MB)    BOOTDISK(GB) PID
       100 VM-Test              stopped    512              32.00 0
       101 VM-Debian-S8         stopped    2048             10.00 0
       102 VM-Clone-S8          stopped    2048             10.00 0
       103 VM-FullClone-S8      stopped    2048             10.00 0
root@pve:~# qm config 100
boot: order=scsi0;ide2;net0
cores: 1
cpu: x86-64-v2-AES
ide2: none,media=cdrom
memory: 512
meta: creation-qemu=9.2.0,ctime=1781899361
name: VM-Test
net0: virtio=BC:24:11:BD:12:A6,bridge=vmbr0,firewall=1
numa: 0
ostype: l26
scsi0: local-lvm:vm-100-disk-0,iothread=1,size=32G
scsihw: virtio-scsi-single
smbios1: uuid=873adaa6-6221-4530-ab7d-0893abfc0781
sockets: 1
vmgenid: a15854c3-d94a-4f53-9bf1-681256e55e24
root@pve:~# _
```

qm list et qm config 100 avant l'opération : disque sur local-lvm, 32 Go

Incident : le déplacement du disque (qm disk move, équivalent de « Move Storage ») a provoqué un plantage de la VM pve (« Guru Meditation » VirtualBox) à 1 %, par manque de ressources sur le PC hôte. Le disque d'origine n'a pas été touché (la suppression n'a lieu qu'après une copie réussie). Après redémarrage de pve, nous avons supprimé la copie incomplète avec pvesm free.

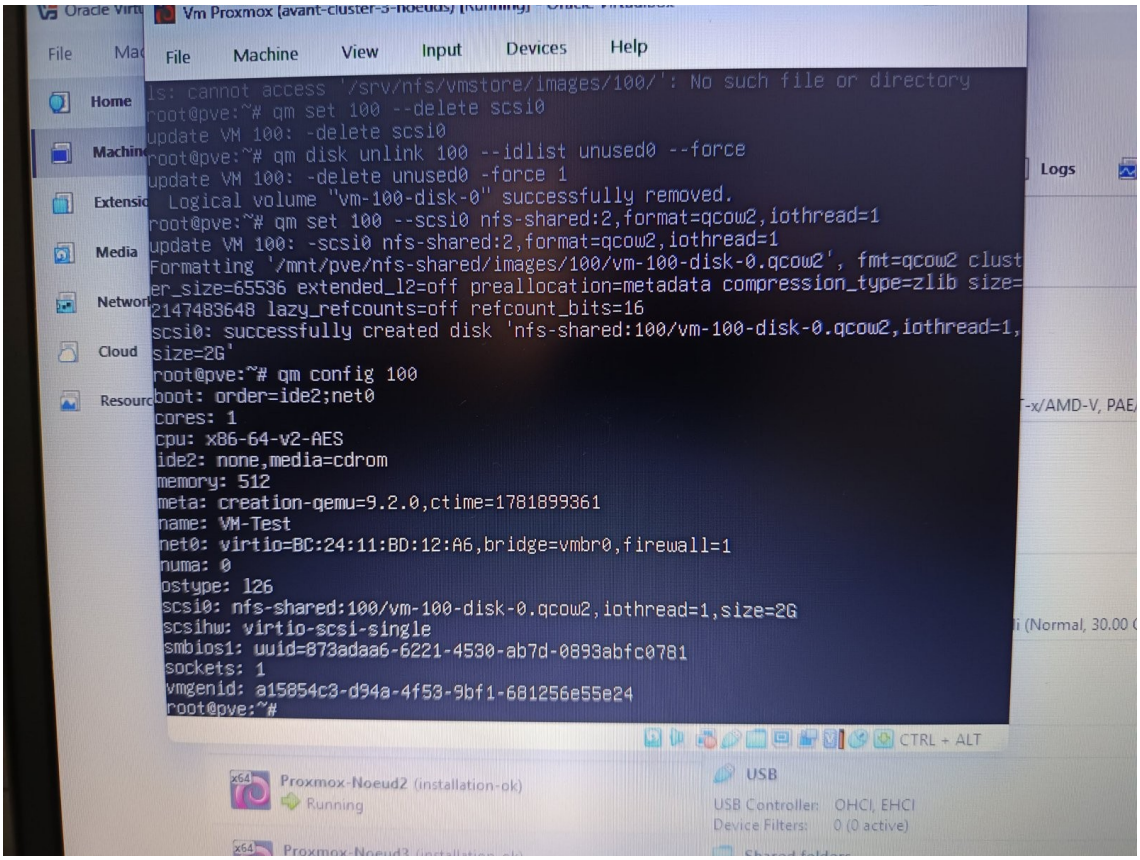


Plantage de la VM pve pendant la copie du disque (Guru Meditation)

La commande lvs a montré que le disque de VM-Test était vide (Data% = 0,00). Nous l'avons donc remplacé par un disque de 2 Go créé directement sur nfs-shared : qm set 100 --delete scsi0, qm disk unlink 100 --idlist unused0 --force, puis qm set 100 --scsi0 nfs-shared:2,format=qcow2,iothread=1. Résultat identique pour la suite du TP : le disque de la VM est sur le stockage partagé.

```
  vm-100-disk-0                          pve Vwi-a-tz--  32.00g data
                   0.00
  vm-102-disk-0                          pve Vwi-a-tz--  10.00g data snap_vm-102-d
isk-0_snap-apache-ok 20.44
  vm-102-state-snap-apache-ok            pve Vwi-a-tz--  <4.49g data
                   11.80
  vm-102-state-snap-exercices-s9         pve Vwi-a-tz--  <4.49g data
                   5.86
  vm-103-disk-0                          pve Vwi-a-tz--  10.00g data
                   20.18
  vm-104-disk-0                          pve Vwi-a-tz--   4.00g data
                   3.63
  vm-105-disk-0                          pve Vwi-a-tz--   8.00g data
                   2.60
  vm-106-disk-0                          pve Vwi-a-tz--   8.00g data
                   2.60
  vm-110-disk-0                          pve Vwi-a-tz--   2.00g data
                   19.69
  vm-110-disk-1                          pve Vwi-a-tz--   2.00g data
                   32.53
  vm-111-disk-0                          pve Vwi-a-tz--   2.00g data
                   29.52
  vm-112-disk-0                          pve Vwi-a-tz--   2.00g data
                   32.57
  vm-113-disk-0                          pve Vwi-a-tz--   2.00g data
                   32.58
  vm-114-disk-0                          pve Vwi-a-tz--   2.00g data
                   32.53
root@pve:~# _
```

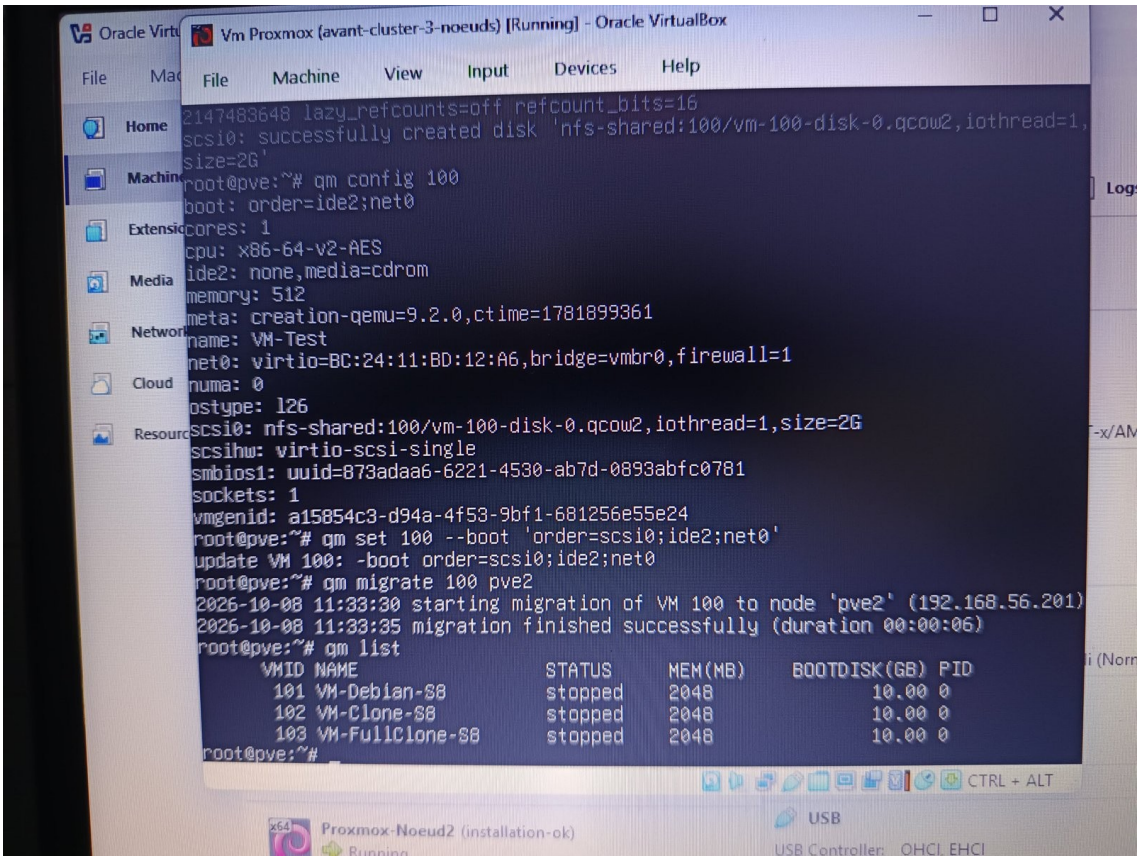
lvs : vm-100-disk-0 à 0,00 % (disque vide)



qm config 100 : scsi0: nfs-shared:100/vm-100-disk-0.qcow2, size=2G

3.5 — Migration de VM-Test vers pve2

Ordre de démarrage rétabli (qm set 100 --boot 'order=scsi0;ide2;net0'), puis qm migrate 100 pve2. La migration a duré 6 secondes : seule la configuration de la VM est déplacée, le disque reste sur nfs-shared et n'est pas copié.

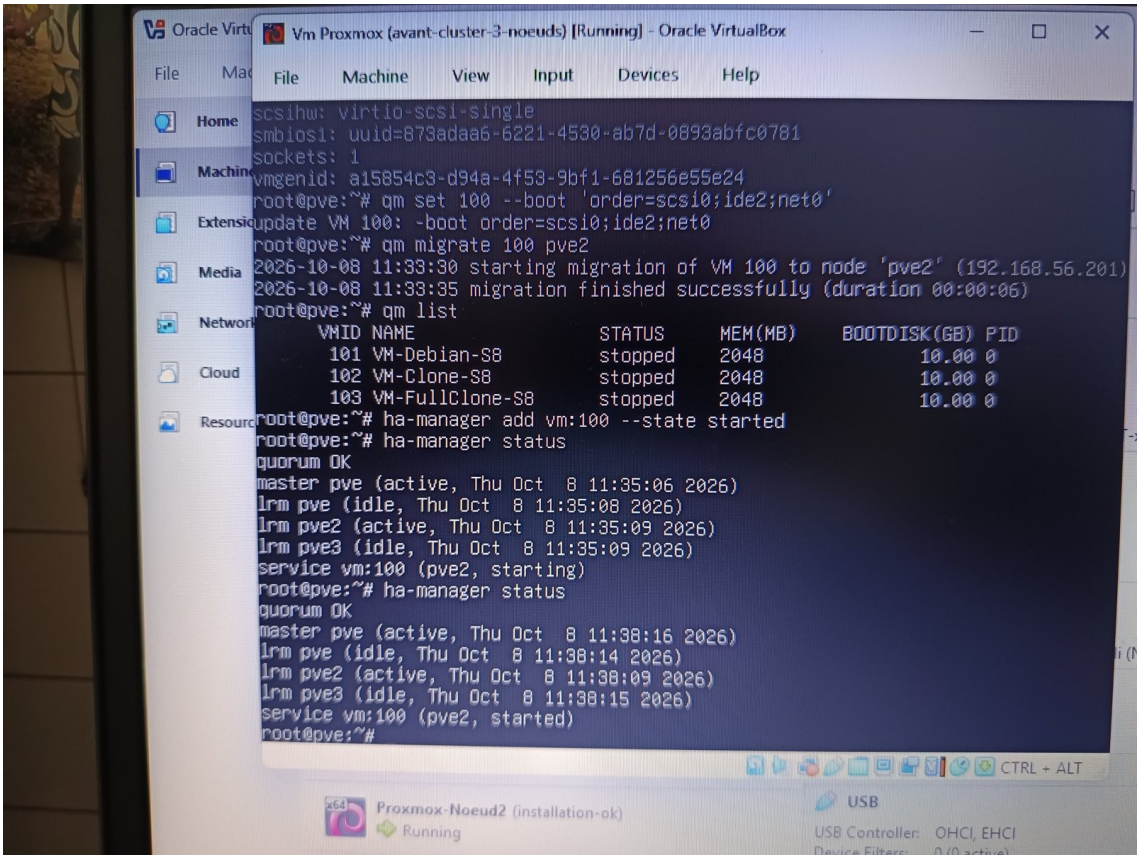


migration finished successfully (duration 00:00:06) ; VM 100 n'apparaît plus sur pve

PARTIE 4 — Haute disponibilité et test de panne

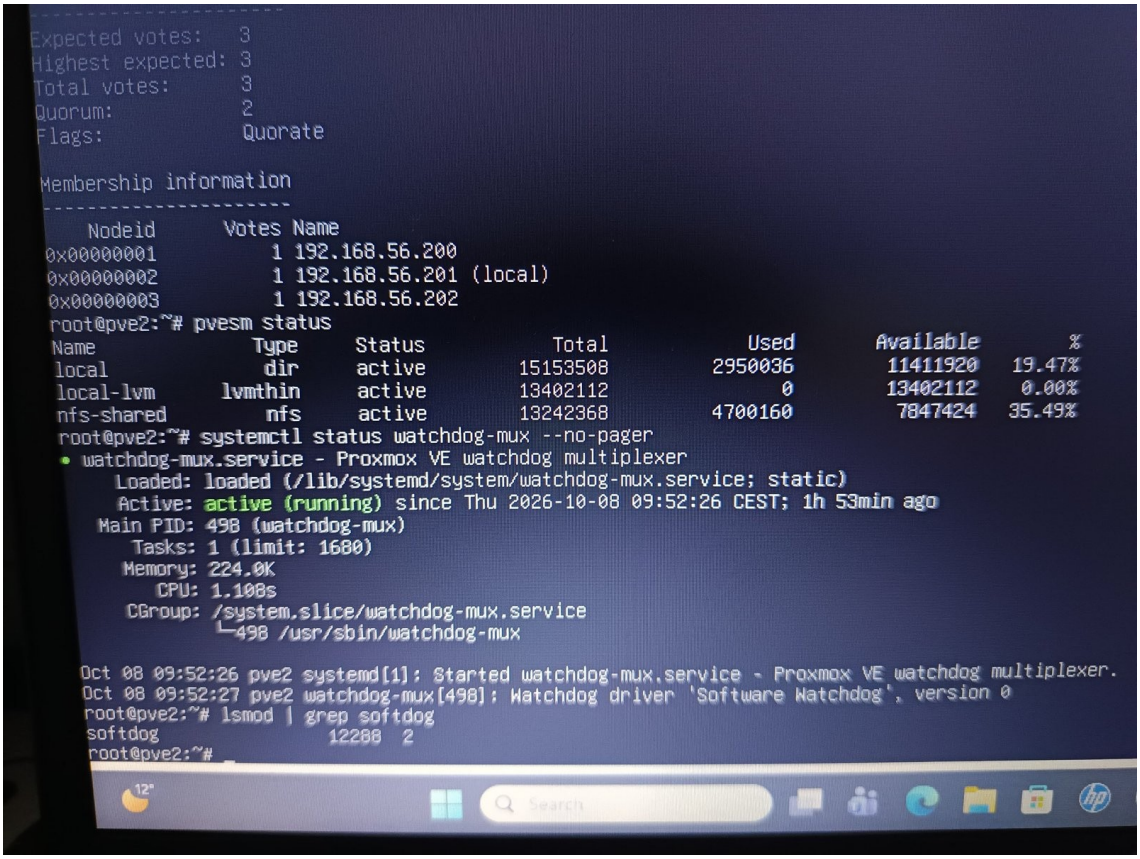
4.1 — Activation de la HA sur VM-Test

Commande : ha-manager add vm:100 --state started. La HA démarre la VM sur pve2.



ha-manager status : quorum OK, service vm:100 (pve2, started)

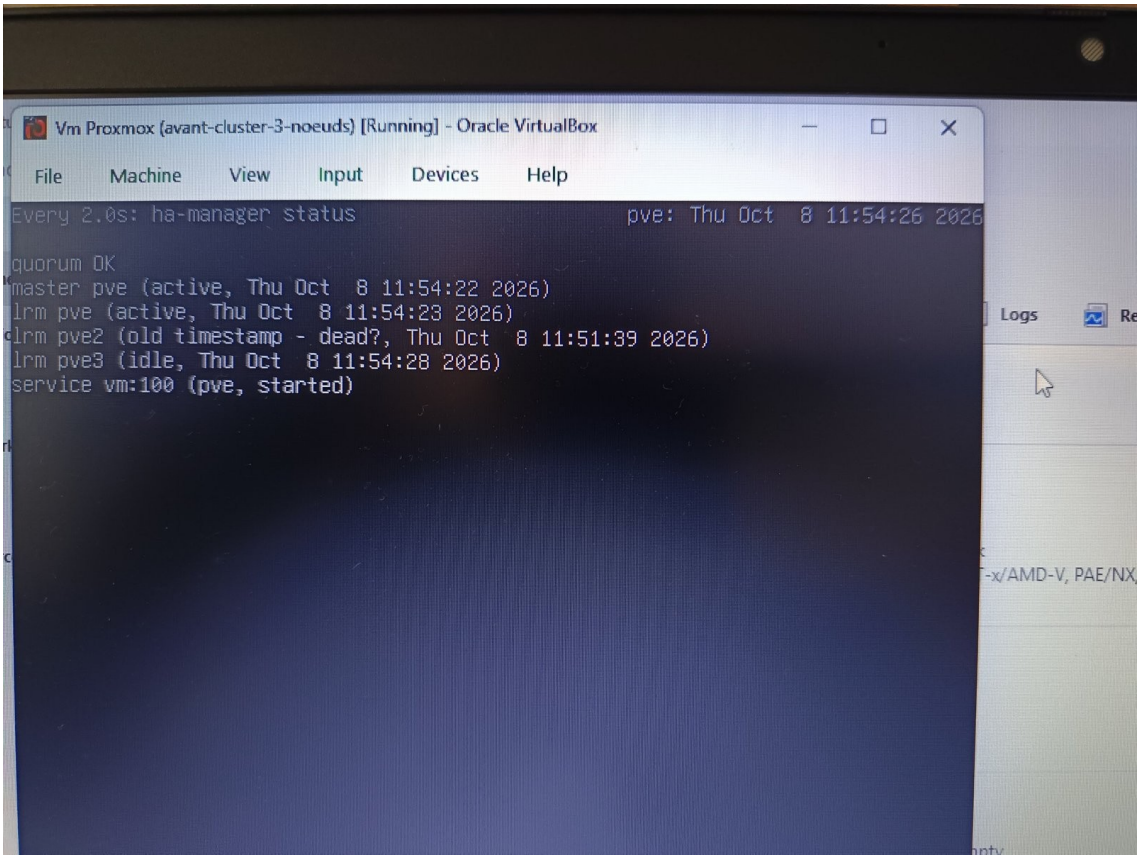
Mécanisme de surveillance sur le nœud hôte (pve2) : watchdog-mux est actif et utilise le « Software Watchdog » ; le module softdog est chargé. Si un nœud se fige, le watchdog le redémarre pour qu'il ne puisse pas continuer à faire tourner la VM pendant qu'elle est relancée ailleurs.



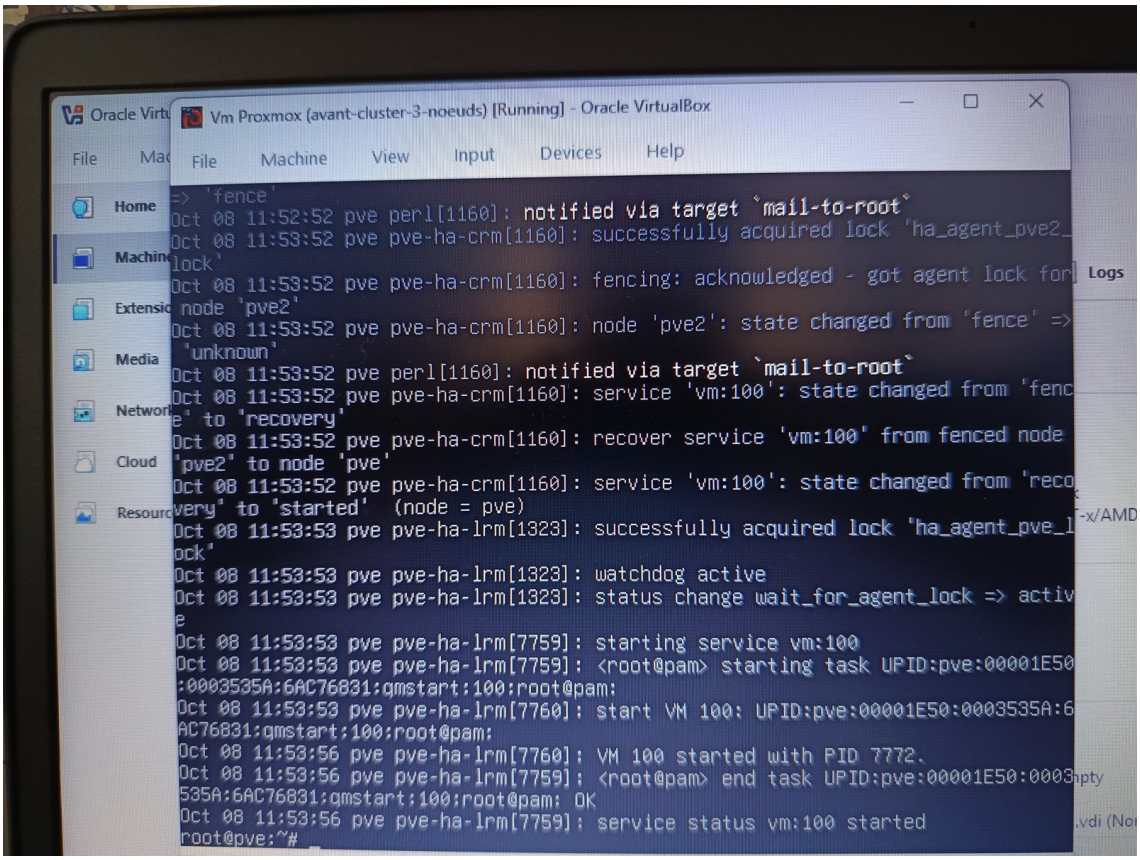
pve2 : watchdog-mux active (running), Software Watchdog, lsmod | grep softdog

4.2 — Test de panne et mesure du RTO

Arrêt brutal de pve2 dans VirtualBox (Machine > Fermer > Éteindre la machine). Les heures sont lues dans les journaux de la HA (journalctl -u pve-ha-crm -u pve-ha-lrm).



ha-manager status après la panne : pve2 « old timestamp - dead? », vm:100 (pve, started)



Journaux HA : fencing de pve2, recover service vm:100 vers pve, VM 100 started

Mesure	Valeur
t0 : arrêt du nœud (dernier signal de pve2)	11:51:39
t1 : service relancé (ha-manager)	11:53:52
t2 : VM de nouveau utilisable (VM 100 started)	11:53:56
RTO mesuré (t2 moins t0)	2 min 17 s
Calcul	11:53:56 − 11:51:39 = 2 min 17 s (137 s)
RTO cible (fixée par le groupe, voir ci-dessous)	15 min
Écart	15 min − 2 min 17 s = 12 min 43 s de marge : CONFORME

Preuves : t0 est lisible sur la capture ha-manager status (« lrm pve2 (old timestamp - dead?, … 11:51:39) ») ; t1 et t2 sont lisibles sur la capture du journal HA (« recover service 'vm:100' … 11:53:52 » et « VM 100 started … 11:53:56 »). Calcul vérifié à la main : de 11:51:39 à 11:53:39 = 2 min, puis + 17 s = 2 min 17 s.

Cible du CDC : notre CDC ne chiffre pas le RTO (« à confirmer avec le client »). Le groupe fixe donc la cible à 15 min pour la panne d'un nœud. Justification : la prise de rendez-vous en ligne est le service critique de Santélia ; la panne de mars l'a bloquée plus de 6 h ; une coupure de 15 min reste supportable pour les patients et l'accueil (prise de rendez-vous par téléphone pendant ce temps), et la HA relance la VM sans intervention de la DSI, qui ne compte que 2 personnes.

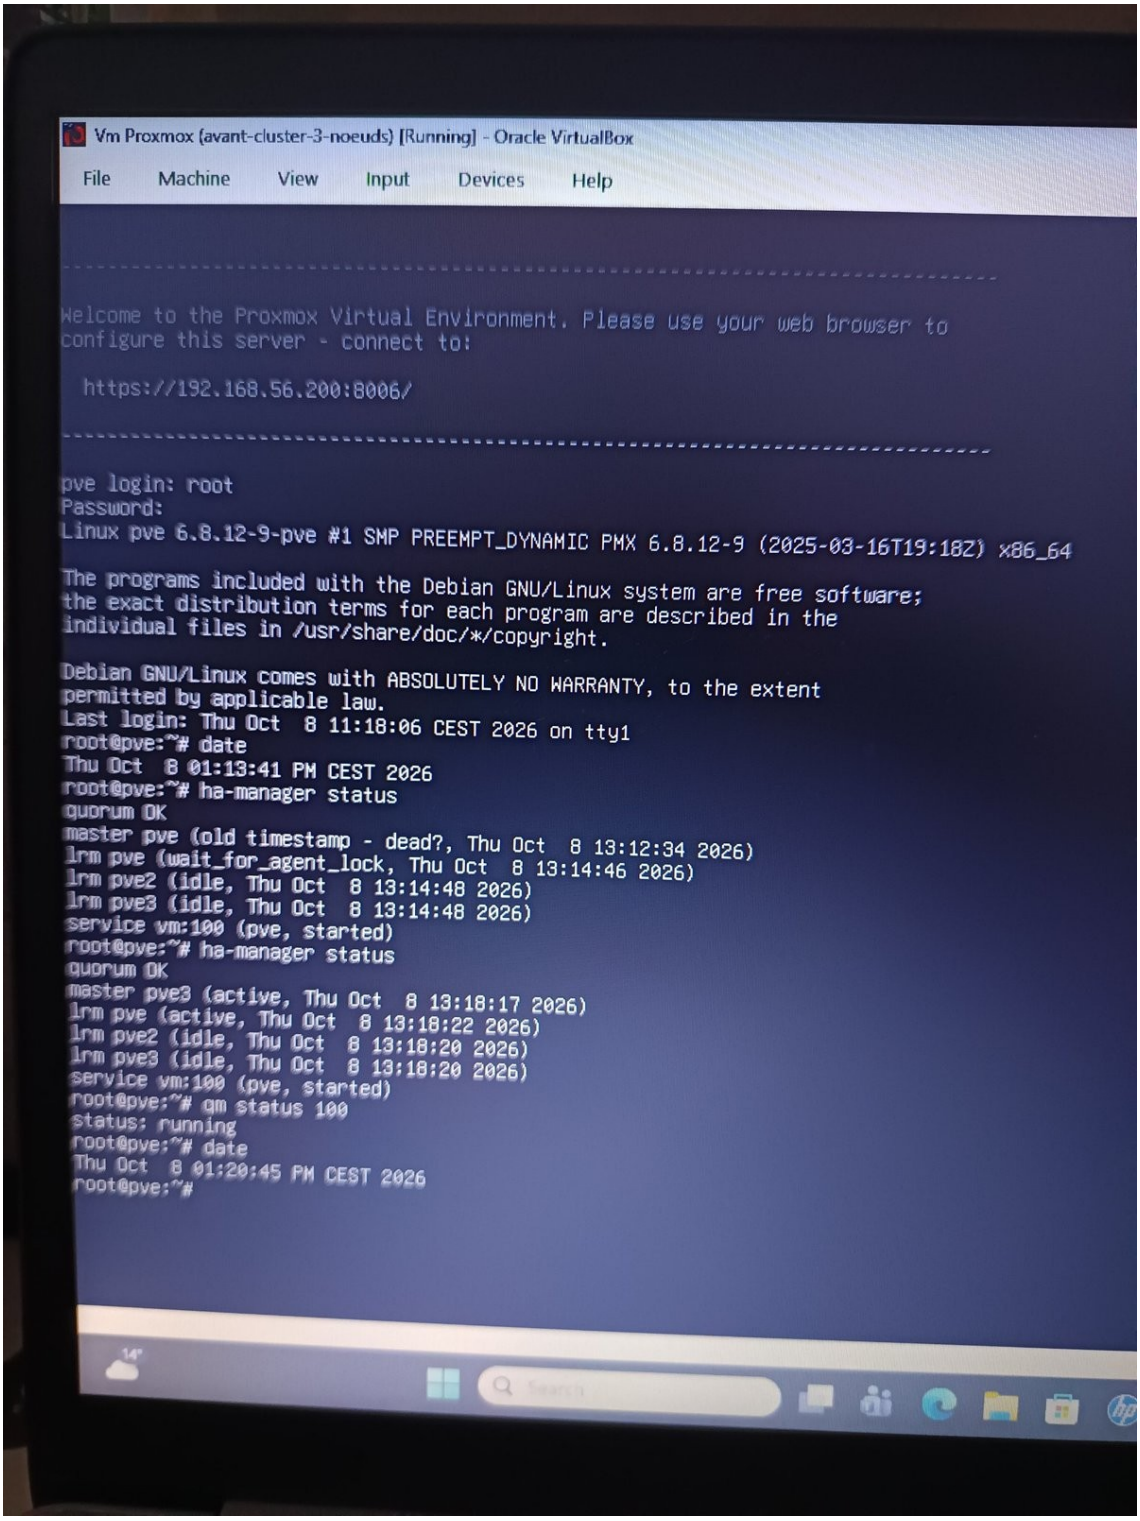
Analyse : presque tout le délai (environ 2 min 13 s) correspond à l'attente de sécurité pendant laquelle Proxmox s'assure que pve2 est vraiment arrêté (fencing) avant de relancer la VM. Le redémarrage lui-même a pris 4 secondes. La HA a choisi de relancer la VM sur pve (et non sur pve3) : c'est la HA qui choisit le nœud cible parmi les nœuds disponibles.

Limites : t0 est le dernier signal de pve2, quelques secondes avant l'arrêt réel. VM-Test n'a pas de système d'exploitation : « utilisable » signifie ici « VM démarrée ». Avec un vrai système, il faudrait ajouter son temps de démarrage (30 à 60 s environ).

Remise en état

pve2 a été rallumé et a rejoint le cluster (Nodes: 3, Quorate: Yes). La VM est restée sur pve : Proxmox ne remet pas automatiquement une VM sur son nœud d'origine (pas de « failback »), pour éviter une deuxième interruption.

Incident : après une mise en veille du PC hôte, les horloges de pve et pve3 avaient environ 36 min de retard (la HA a signalé « detected time drift »). La correction brutale de l'heure (chronyc makestep) a entraîné un redémarrage automatique de pve par son watchdog (auto-protection de la HA). La HA a ensuite tout remis en ordre seule : le rôle de maître est passé à pve3 et VM-Test est de nouveau running. Leçon : la synchronisation de l'heure (NTP) est indispensable dans un cluster.



État final : quorum OK, master pve3, vm:100 (pve, started), qm status 100 : running

Questions de compréhension

1. Pourquoi la VM ne peut-elle pas redémarrer ailleurs si son disque est stocké uniquement sur le nœud tombé ?

Le disque d'une VM est un fichier (ou un volume) qui contient tout son système et ses données. S'il est stocké sur le disque local du nœud tombé, les autres nœuds n'y ont pas accès : ils peuvent lire la configuration de la VM, mais pas son disque. Sans disque, la VM ne peut pas démarrer. C'est pour cela que nous avons placé le disque sur un stockage partagé (NFS), accessible par les 3 nœuds. Une autre solution est la réplication ZFS, qui copie régulièrement le disque sur les autres nœuds.

2. Quelle est la différence entre PCA et PRA sur le cas Santélia ?

Le PCA (Plan de Continuité d'Activité) sert à continuer le service pendant une panne, avec une coupure nulle ou très courte. Pour Santélia : si un serveur tombe, le cluster relance automatiquement le logiciel de rendez-vous ou de dossiers patients sur un autre serveur en quelques minutes (2 min 17 s dans notre test).

Le PRA (Plan de Reprise d'Activité) sert à redémarrer après un sinistre plus grave, quand le site entier ou les données sont touchés : incendie de la salle serveur, rançongiciel. On restaure alors à partir des sauvegardes (Proxmox Backup Server, copie hors site, règle 3-2-1). La reprise est plus longue (plusieurs heures) et on peut perdre les données depuis la dernière sauvegarde (RPO).

3. Votre RTO mesuré respecte-t-il l'exigence de votre CDC ? Sinon, que faudrait-il changer : la solution technique ou l'exigence ?

Notre CDC ne chiffrait pas le RTO ; le groupe a fixé la cible à 15 min pour la panne d'un nœud (justification ci-dessus, Partie 4.2). RTO mesuré : 2 min 17 s, soit 12 min 43 s de marge : la cible est respectée, il n'y a rien à changer. Si la direction exigeait une coupure de moins d'une minute, il faudrait changer la solution technique (applications en mode actif-actif, répartition de charge), car l'attente de sécurité (fencing) de la HA dure à elle seule environ 2 minutes.

Point d'amélioration : dans notre lab, le partage NFS est hébergé sur pve. Si pve tombe, le stockage partagé disparaît : c'est un point unique de défaillance. En production, il faudrait un stockage partagé lui-même redondant (NAS en haute disponibilité ou Ceph), et faire valider par le client un RTO et un RPO chiffrés.

TP HD/PCA — Séance B : sauvegarder, restaurer, rédiger le plan de reprise

GRETA de l'Essonne — Titre professionnel AIS — Bloc 2 : Conception et évolution

Formateur : Samir KECHEMIR

Charles Maduba — Groupe 3 (travail réalisé en groupe de 4 stagiaires)

Séance B : lundi 12 octobre 2026. Suite de la séance A (cluster, NFS, HA, RTO = 2 min 17 s).

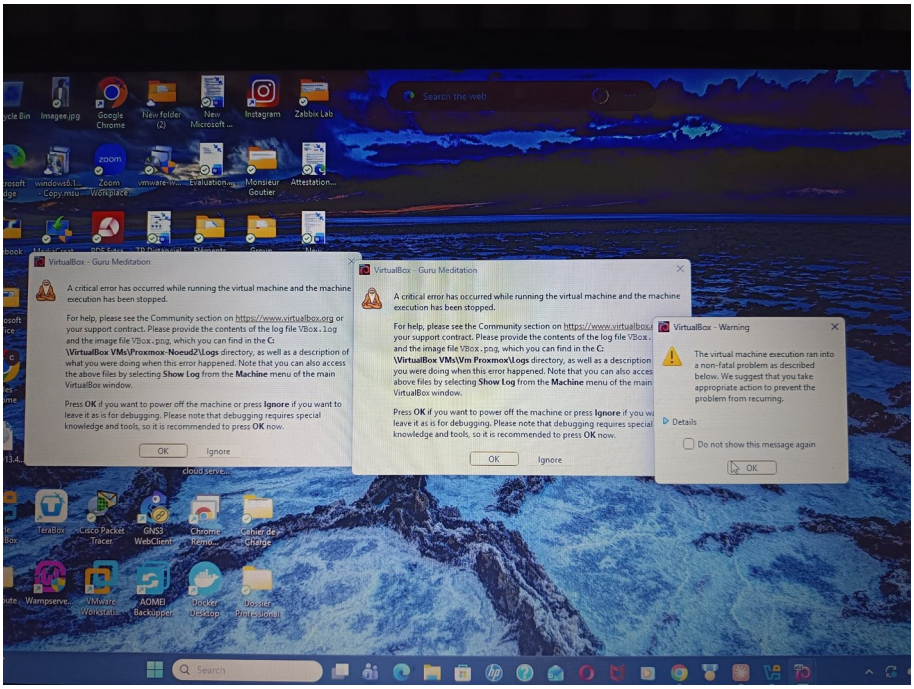
Synthèse

Partie	Contenu	Résultat
0	Rattrapage : cluster, HA, disque partagé	Vérifié
1	Sauvegarde, restauration, sauvegarde automatique	Sauvegarde 10 s, restauration 3,6 s, tâche quotidienne 21:00 (7 conservées)
2	RPO	Estimé par scénario (VM sans système)
3	Plan de reprise d'activité (PRA)	Rédigé (6 rubriques)
4	Restitution croisée	Valeurs du groupe 3 prêtes

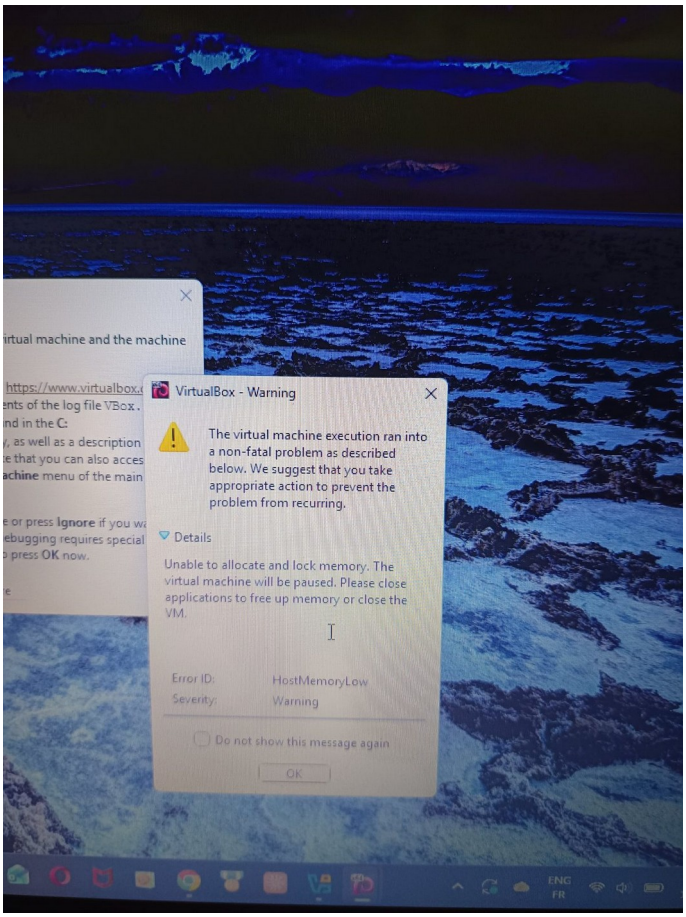
Toutes les opérations ont été faites en ligne de commande (vzdump, qmrestore, pvesh) : avec les 3 nœuds allumés, le PC hôte n'a pas assez de mémoire pour ouvrir l'interface web. Ces commandes sont les équivalents documentés des boutons de l'interface (le TP les cite).

Incident au démarrage : mémoire insuffisante sur le PC hôte

Au premier démarrage des 3 nœuds, VirtualBox a arrêté pve et pve2 (« Guru Meditation ») avec l'erreur HostMemoryLow : « Unable to allocate and lock memory ». Les 3 nœuds demandent 6 Go de RAM sur un PC de 11,8 Go où Chrome, l'application Claude et WhatsApp tournaient aussi. Après fermeture de ces applications, les 3 nœuds ont démarré normalement.



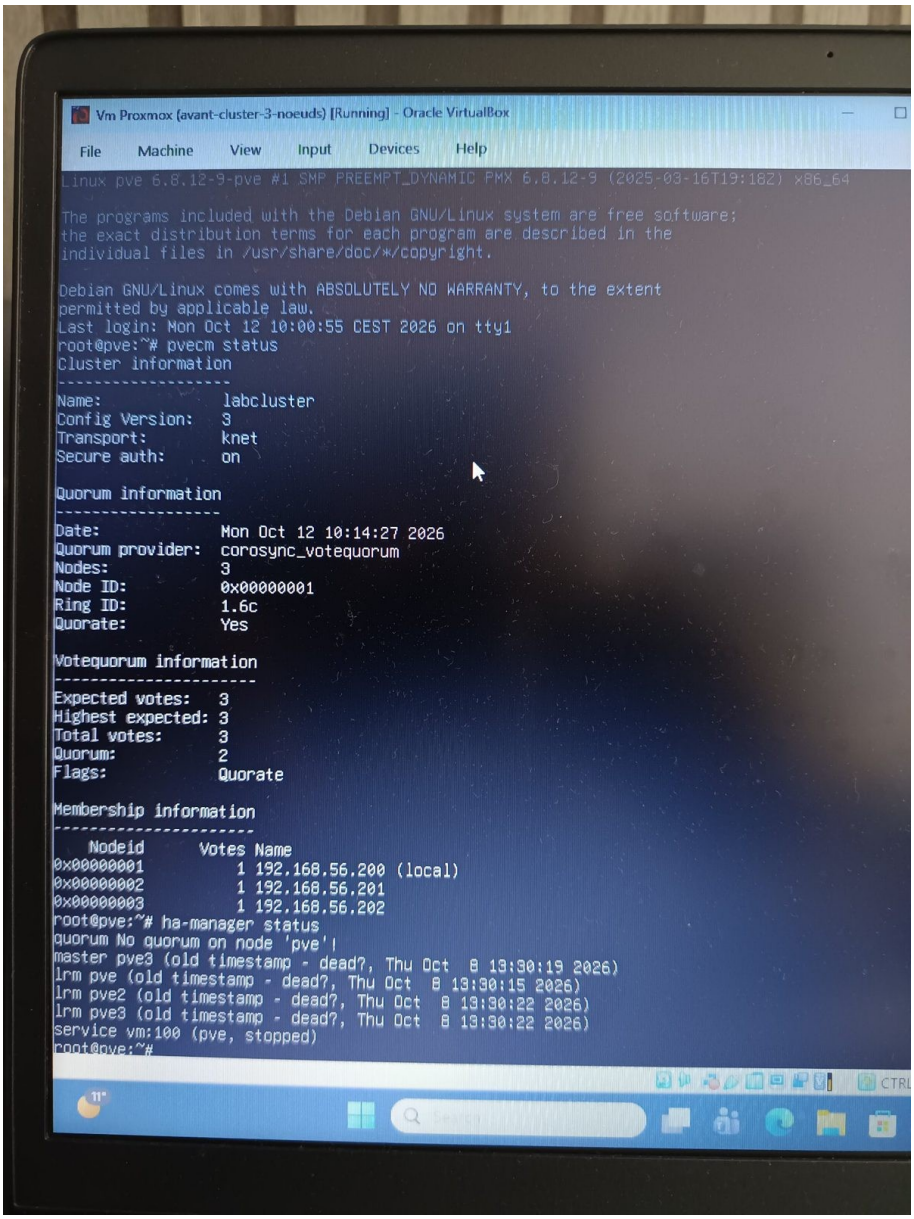
Arrêt de pve et pve2 par VirtualBox (Guru Meditation)



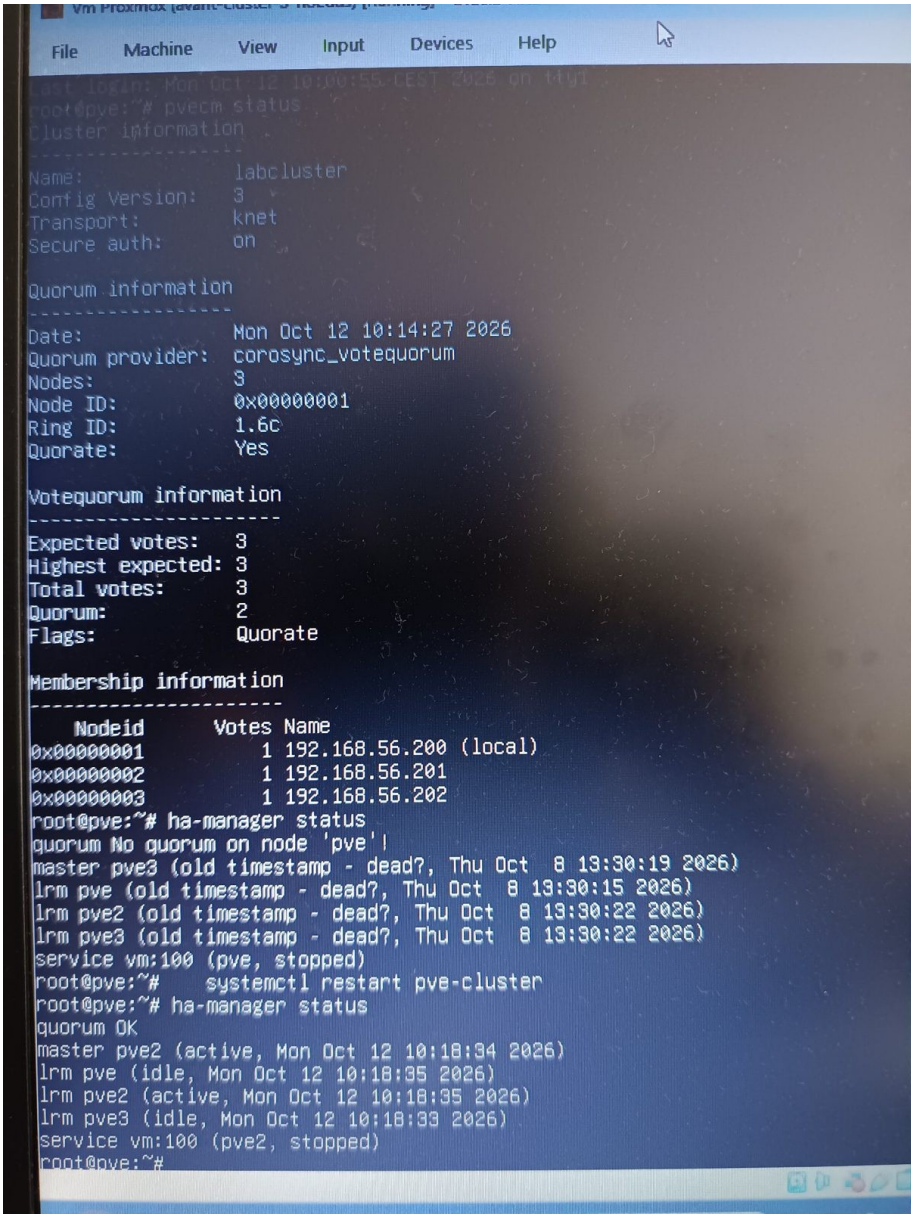
Détail de l'erreur : HostMemoryLow

PARTIE 0 — Vérification de la séance A

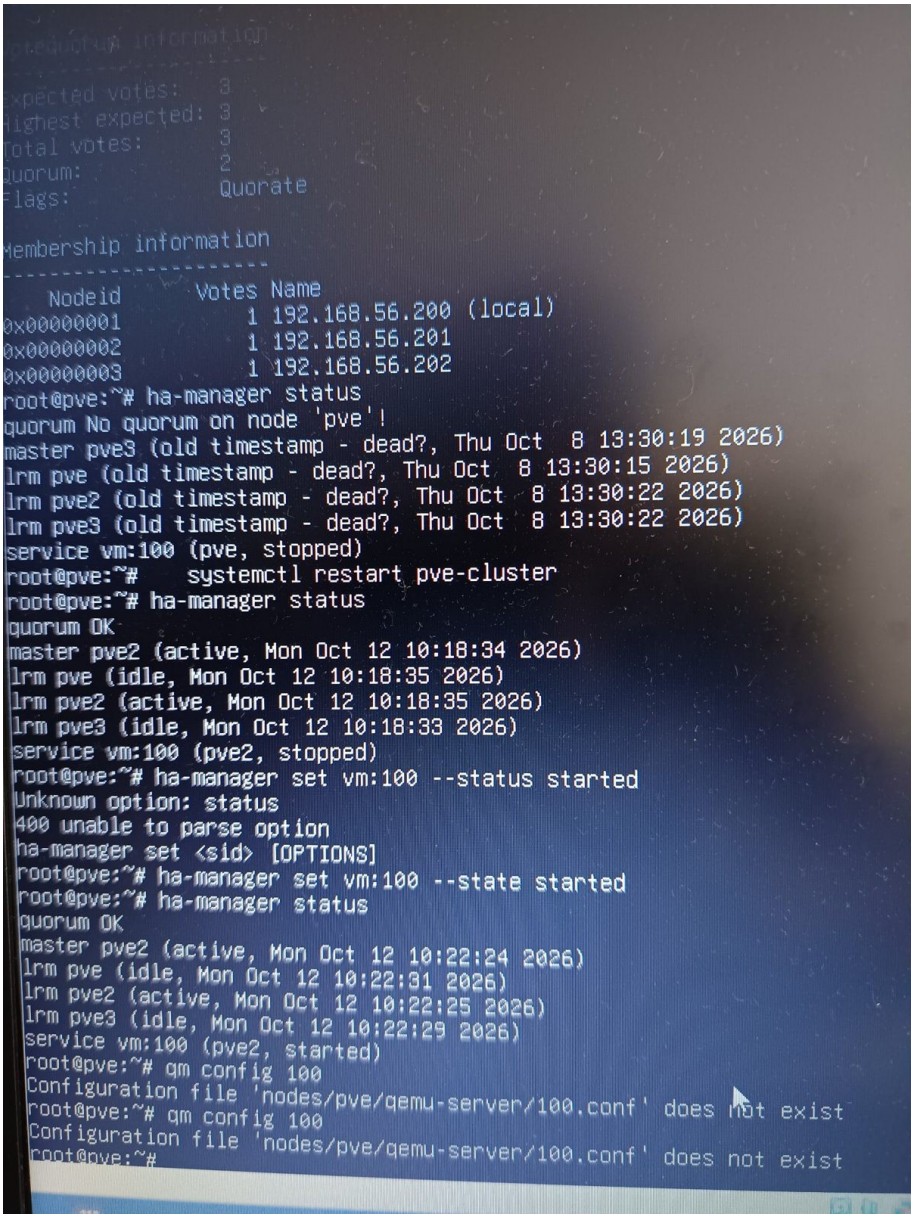
pvecm status indiquait 3 votes et Quorate: Yes, mais ha-manager status affichait « No quorum on node 'pve' » avec des horodatages du 8 octobre : le service de configuration du cluster (pmxcfs) était resté bloqué au démarrage. Corrigé avec systemctl restart pve-cluster (même problème qu'en séance A). La HA a alors repris la main et replacé VM-Test sur pve2.



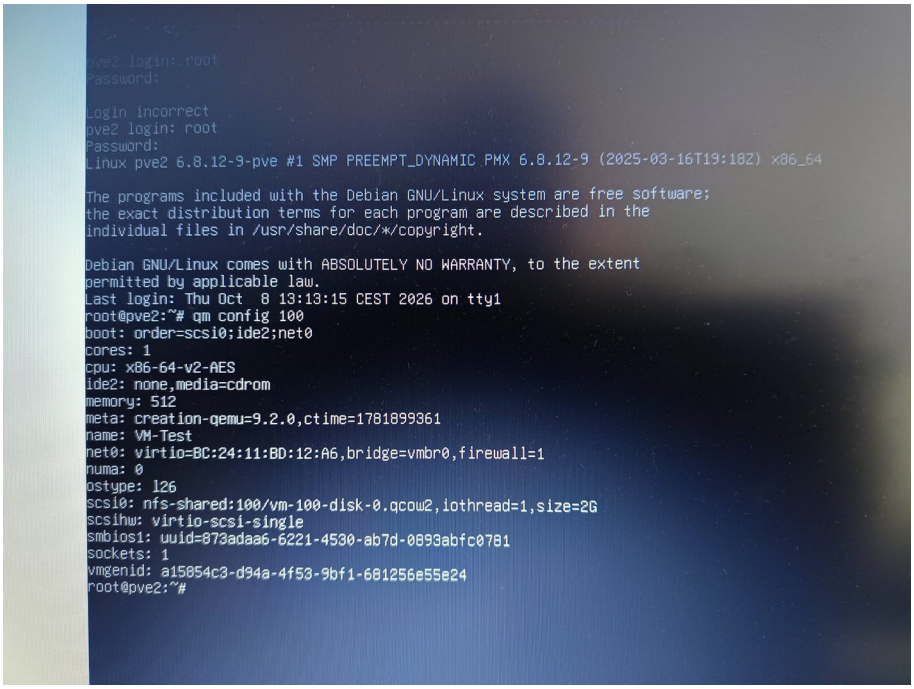
pvecm status : 3 votes, Quorate: Yes ; ha-manager : horodatages du 8 octobre



Après systemctl restart pve-cluster : quorum OK, VM 100 sur pve2



ha-manager set vm:100 --state started → service vm:100 (pve2, started)

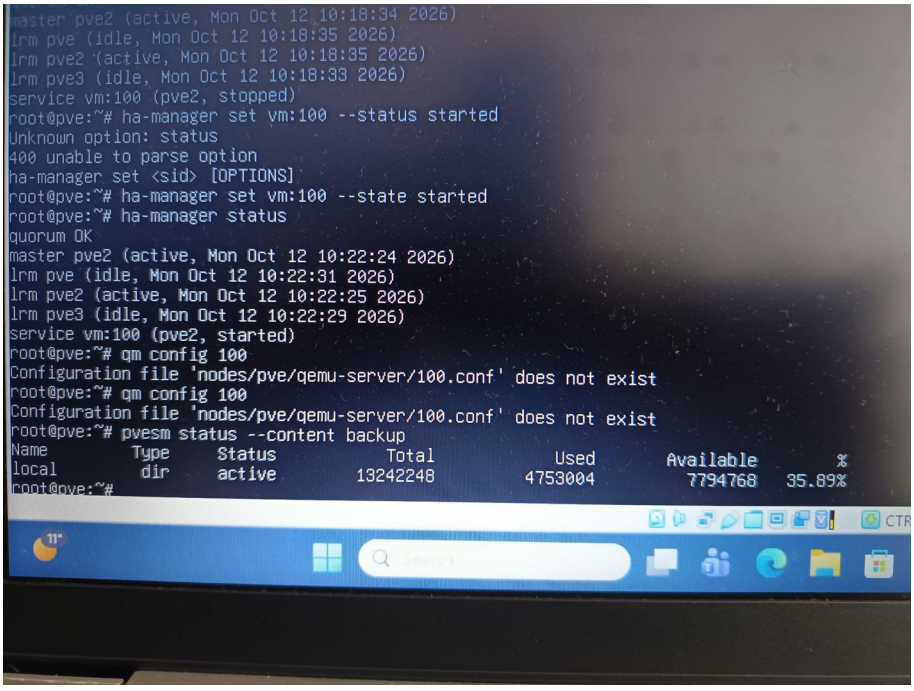


qm config 100 sur pve2 : disque scsi0 sur nfs-shared, 2 Go

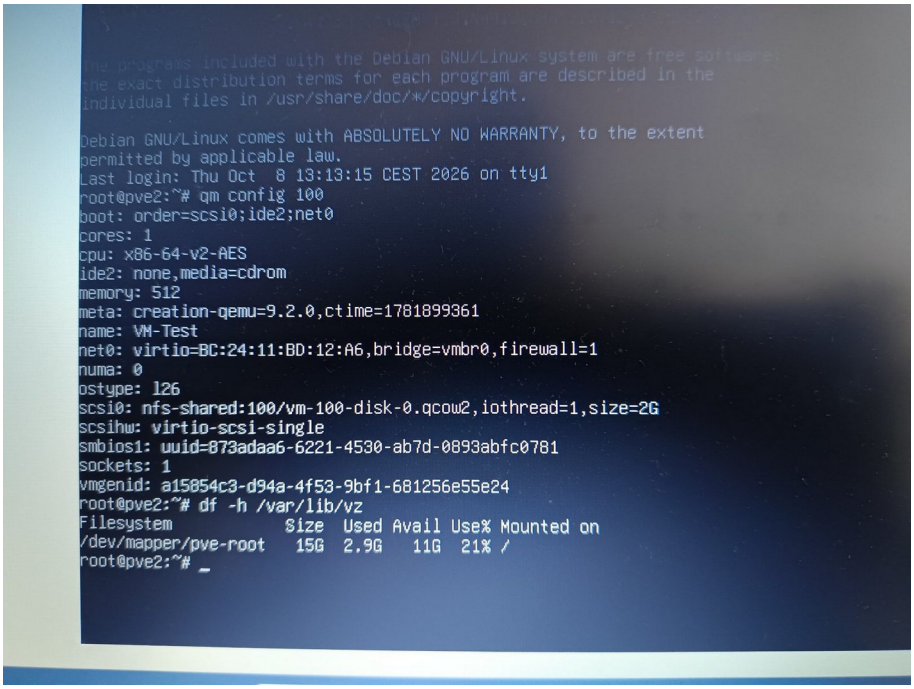
PARTIE 1 — Sauvegarder et restaurer

1.1 — Où ranger les sauvegardes

Le stockage local (/var/lib/vz) accepte les sauvegardes. Sur pve2 (nœud qui héberge la VM), 11 Go sont libres, bien plus que les 2 Go du disque de VM-Test.



pvesm status --content backup : local, dir, active

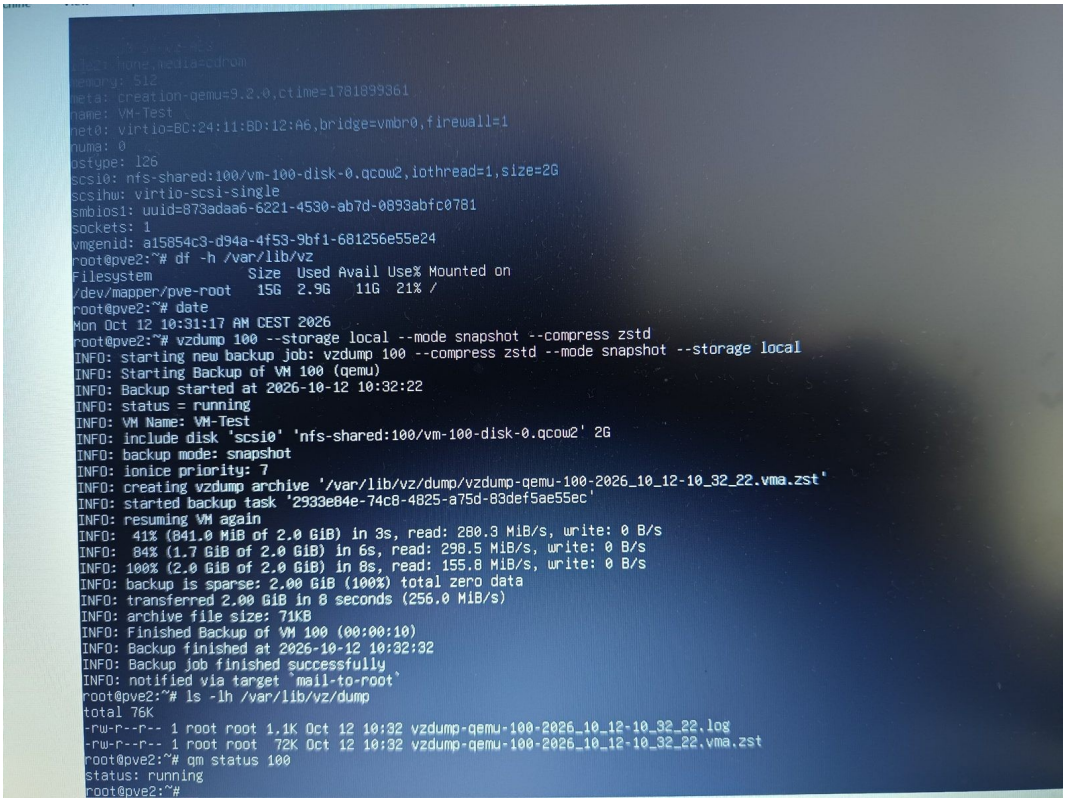


df -h /var/lib/vz sur pve2 : 11 Go disponibles

1.2 — Sauvegarde manuelle

```
vzdump 100 --storage local --mode snapshot --compress zstd
```

Mesure	**Valeur**
Début / fin	10:32:22 / 10:32:32
Durée	10 secondes
Taille de l'archive	72 Ko (disque de 2 Go entièrement vide : « sparse 100 % »)
La VM continue de tourner ?	Oui : mode snapshot, qm status 100 → running



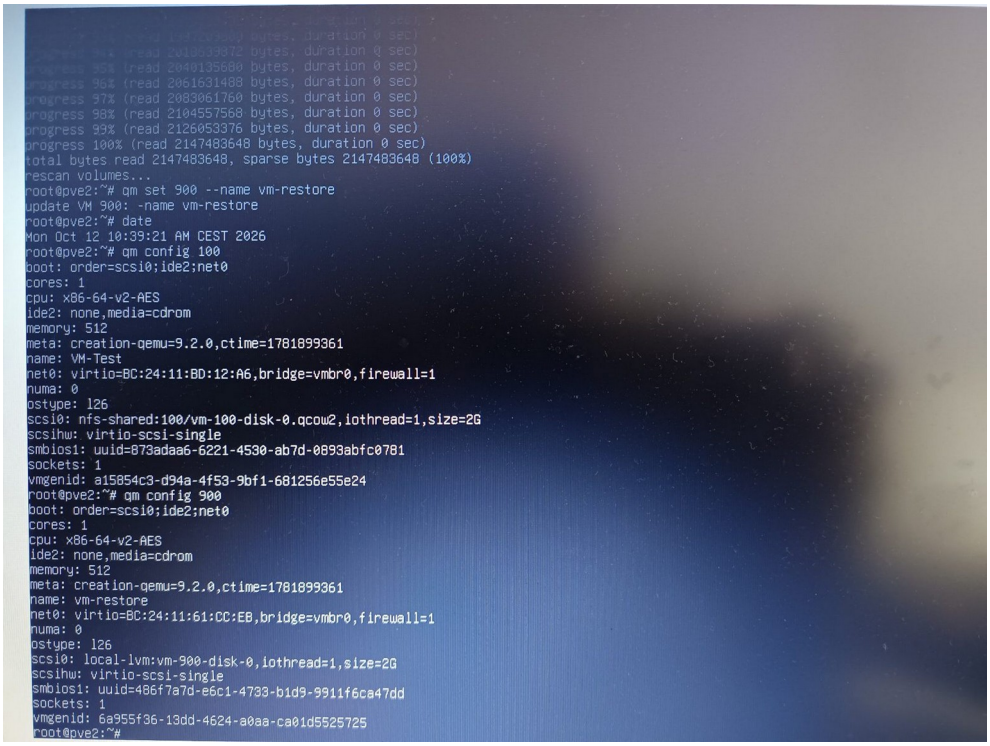
Sauvegarde vzdump terminée avec succès, archive dans /var/lib/vz/dump, VM toujours running

1.3 — Restauration de test sous l'ID 900

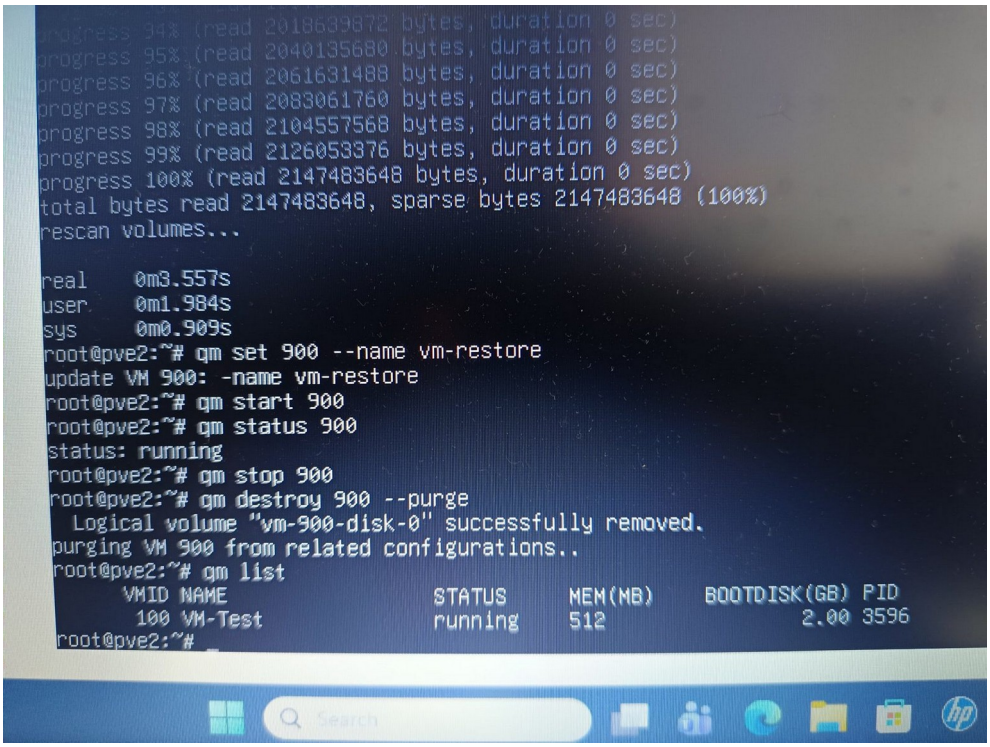
`qmrestore /var/lib/vz/dump/vzdump-qemu-100-2026_10_12-10_32_22.vma.zst 900 --storage local-lvm --unique 1`

La restauration se fait sous un autre numéro (900), sur local-lvm, avec --unique (nouvelle adresse MAC), pour ne pas écraser la VM 100 en service ni perturber la HA. La première restauration a réussi mais son heure de début n'était plus visible à l'écran ; elle a été refaite avec la commande time, qui mesure la durée exacte.

	VM 100 (VM-Test)	**VM 900 (vm-restore)**
RAM / CPU	512 Mo / 1	identique
Disque	nfs-shared, 2 Go	local-lvm, 2 Go
Adresse MAC	BC:24:11:BD:12:A6	BC:24:11:61:CC:EB (différente)
Durée de restauration	—	3,6 s (real 0m3.557s)



Comparaison qm config 100 / qm config 900



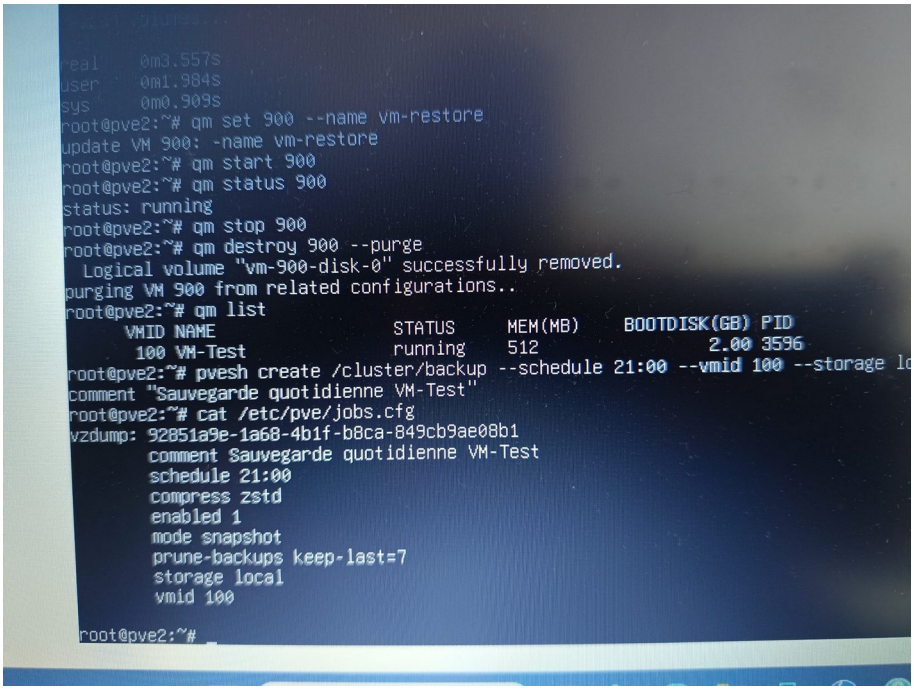
Restauration chronométrée (3,6 s), VM 900 démarrée (running) puis supprimée ; il ne reste que VM 100

VM-Test n'a pas de système d'exploitation : la preuve de démarrage est l'état « running » (la console n'afficherait que le BIOS). La durée de 3,6 s n'est pas représentative d'une vraie VM : un disque de 50 Go plein prendrait plusieurs minutes.

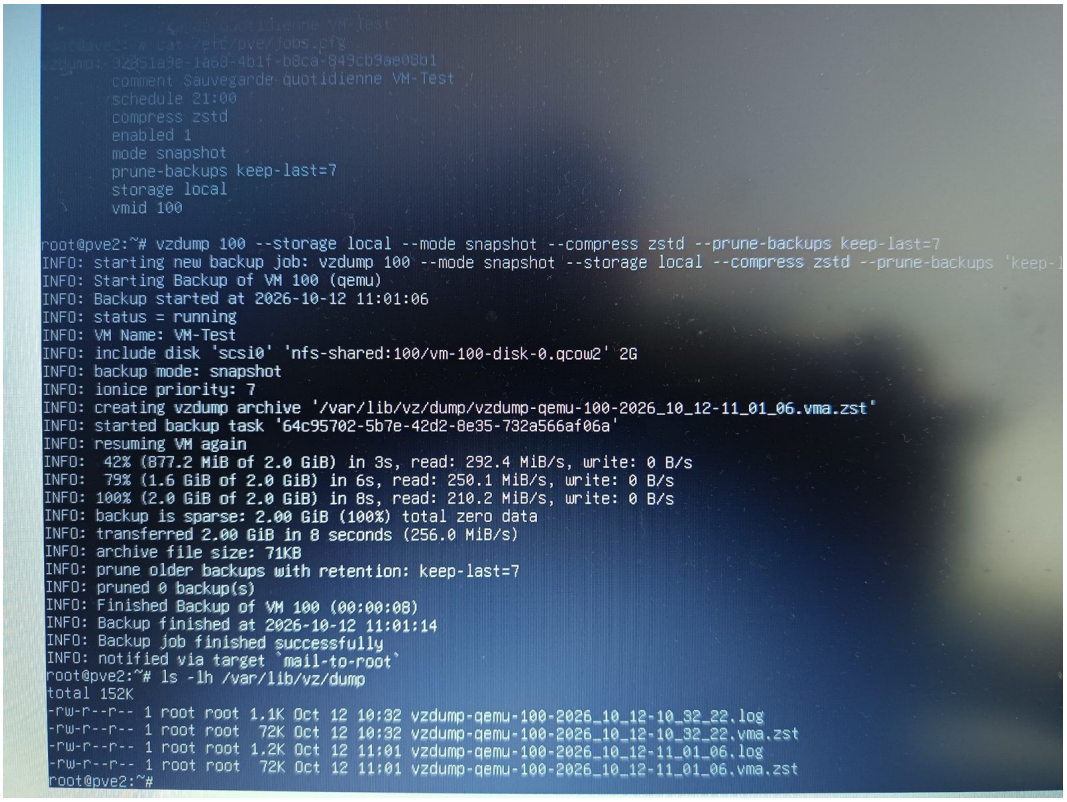
1.4 — Sauvegarde automatique

```
pvesh create /cluster/backup --schedule 21:00 --vmid 100 --storage local --mode snapshot --compress zstd --prune-backups keep-last=7 --enabled 1
```

Tâche planifiée chaque jour à 21:00, en mode snapshot, avec une rétention de 7 sauvegardes (les plus anciennes sont supprimées automatiquement). Le « Run now » a été réalisé en lançant vzdump avec les mêmes paramètres : sauvegarde en 8 s, « pruned 0 backup(s) » (rien à supprimer, seulement 2 sauvegardes).



/etc/pve/jobs.cfg : schedule 21:00, prune-backups keep-last=7



« Run now » : nouvelle sauvegarde à 11:01, 2 sauvegardes dans le stockage local

1.5 — Le lab respecte-t-il la règle 3-2-1 ?

Question	Réponse
Combien de copies du disque ? Où ?	3 : l'original sur nfs-shared (disque de pve) et 2 sauvegardes dans /var/lib/vz/dump sur pve2
Sur combien de supports physiques ?	1 en réalité : les 3 nœuds sont des VM sur le même disque du PC
Une copie hors site ?	Non
Si le PC brûle, que reste-t-il ?	Rien
Que faudrait-il chez Santélia ?	Un Proxmox Backup Server sur un matériel séparé (2e support) et une copie hors site, si possible immuable (contre les rançongiciels), comme prévu dans le CDC

Conclusion : 3 copies, mais ni 2 supports ni copie hors site. Le lab ne respecte donc pas la règle 3-2-1.

PARTIE 2 — Le RPO : combien de données perd-on ?

2.1 — RPO selon le scénario (sauvegarde chaque soir à 21:00)

Scénario	Qui vous sauve ?	RPO (perte maximale)
Le nœud qui héberge la VM tombe en panne	La HA (disque sur le stockage partagé NFS)	≈ 0 (seules les données en mémoire non écrites)
VM supprimée par erreur à 18:00	La sauvegarde de la veille à 21:00 (la HA ne peut rien)	≈ 21 h
Rançongiciel chiffrant les données de la VM	La dernière sauvegarde saine, avant l'infection	≥ 24 h, jusqu'à 7 jours (rétention)
pve1 (serveur NFS) détruit	La sauvegarde stockée sur pve2 (la HA	Jusqu'à 24 h

	ne peut rien : le disque partagé a disparu)	
Groupes en ZFS : réplication toutes les 15 min	Réplication ZFS + HA (non applicable : notre groupe utilise NFS)	Jusqu'à 15 min

La HA protège contre la panne matérielle d'un nœud, pas contre la suppression, le rançongiciel ou la perte du stockage : pour ces cas, seule la sauvegarde permet de revenir en arrière. Limite du lab : les sauvegardes sont sur le même PC que les données.

2.2 — Mesure pratique

Non réalisée : VM-Test n'a pas de système Linux. Le RPO a été estimé (tableau 2.1) et non mesuré, comme le prévoit le TP.

PARTIE 3 — Plan de reprise d'activité (PRA) de Santélia

Document à ouvrir le jour du sinistre. Il doit permettre à une personne qui n'a pas construit l'infrastructure de remettre le service en route.

1. Périmètre

- Services couverts : la prise de rendez-vous en ligne des 3 cliniques (Évry, Corbeil-Essonnes, Ris-Orangis) et le logiciel de dossiers patients, identifiés comme critiques dans le CDC.
- Infrastructure : cluster Proxmox « labcluster » de 3 nœuds (pve, pve2, pve3), disques des VM critiques sur le stockage partagé nfs-shared, VM protégées par la HA.
- Sauvegardes : chaque jour à 21:00, 7 sauvegardes conservées. Dans le lab, la VM de prise de rendez-vous est représentée par VM-Test (VM 100).
- Hors périmètre : postes de travail, téléphonie, matériel médical.

2. Scénarios de sinistre

Scénario	Solution	RTO	RPO	PCA ou PRA ?
Panne d'un nœud	HA + stockage partagé NFS	2 min 17 s (mesuré)	≈ 0	PCA
Panne du serveur de stockage	Restauration depuis sauvegarde sur un autre nœud (local-lvm)	3,6 s mesuré (disque vide) ; estimé 15 à 60 min en production	≤ 24 h	PRA
Suppression accidentelle d'une VM	Restauration depuis la dernière sauvegarde	Idem	≤ 24 h	PRA
Rançongiciel	Isoler, puis restaurer la dernière sauvegarde saine (idéalement copie hors site immuable)	Plusieurs heures (analyse + restauration)	≥ 24 h, jusqu'à 7 j	PRA
Incendie de la salle serveur d'Évry	Reconstruire sur un autre site depuis la copie hors site (à mettre en place)	Plusieurs heures à jours	≤ 24 h si copie hors site quotidienne	PRA

3. Procédure de restauration pas à pas

1. Constater l'incident et prévenir le responsable qui décide de déclencher le PRA (rubrique 4).
2. Se connecter en root sur un nœud qui fonctionne et vérifier le cluster : pvecm status → Quorate: Yes.

3. Trouver la sauvegarde : ls -lh /var/lib/vz/dump/ sur le nœud qui hébergeait la VM (interface web : nœud > local > Backups). Choisir le fichier vzdump-qemu-<id>-<date>.vma.zst le plus récent avant l'incident (rançongiciel : avant l'infection).
4. Restaurer sous un nouvel ID, sans écraser l'ancienne VM : qmrestore <fichier> <nouvel id> --storage local-lvm --unique 1 (interface : Restore, Storage local-lvm, cocher Unique).
5. Vérifier la configuration : qm config <id> (RAM, CPU, disque).
6. Démarrer : qm start <id>, puis qm status <id> → running. Ouvrir la console.
7. Vérifier le service : ouvrir la page de prise de rendez-vous, se connecter avec un compte de test, créer puis annuler un rendez-vous de test.
8. Remettre la VM sous HA : ha-manager add vm:<id> --state started (et retirer l'ancienne ressource HA).
9. Prévenir que le service est rétabli. Noter l'heure de début et de fin (RTO réel) et la période de données perdues (RPO réel) dans le registre d'incidents.

4. Rôles et responsabilités

Rôle	Qui ?	Ce qu'il fait
Décide de déclencher le PRA	La direction de Santélia (par délégation, la DSI hors heures ouvrées)	Évalue l'impact, valide le déclenchement et la perte de données acceptée
Exécute la restauration	La DSI (2 personnes : un titulaire, un suppléant)	Applique la procédure, vérifie le service, consigne les heures
Prévient les cliniques et les patients	Responsable communication / accueil des cliniques, avec la direction	Informe le personnel, organise la prise de rendez-vous par téléphone en mode dégradé, prévient les patients concernés

5. Objectifs comparés aux mesures

Le CDC laisse le RTO et le RPO « à confirmer avec le client ». Conformément à la consigne, le groupe fixe les cibles et les justifie :

- RTO panne d'un nœud : 15 min. La prise de rendez-vous est le service critique ; la panne de mars l'a bloquée plus de 6 h ; 15 min restent supportables (accueil téléphonique en attendant) et la HA agit sans intervention humaine.
- RTO restauration : 4 h. Une DSI de 2 personnes doit pouvoir restaurer en une demi-journée, bien en dessous des 6 h de la panne de mars.
- RPO panne d'un nœud : 0. Le disque est sur un stockage partagé, aucune donnée écrite ne doit être perdue.
- RPO restauration : 4 h. Perdre au plus une demi-journée de rendez-vous, que l'accueil peut reconstituer en rappelant les patients.

Indicateur	Cible (fixée par le groupe)	Mesuré dans le lab	Conforme ?
RTO (panne d'un nœud)	15 min	2 min 17 s (11:53:56 – 11:51:39)	Oui
RTO (restauration)	4 h	3,6 s de restauration (disque vide, à re-mesurer avec une vraie VM)	Oui dans le lab
RPO (panne d'un nœud)	0	≈ 0	Oui
RPO (restauration)	4 h	Jusqu'à 24 h (sauvegarde à 21:00 ; VM supprimée à 18:00 → 21 h perdues)	NON CONFORME

Correction proposée pour le RPO : passer de 1 sauvegarde par jour à 1 sauvegarde toutes les 4 h (en mode snapshot, sans interruption du service). C'est la fréquence de sauvegarde qu'il faut changer, pas la cible : perdre une journée entière de rendez-vous n'est pas acceptable pour Santélia.

6. Tests et mise à jour du plan

- Chaque jour : contrôle automatique du résultat des sauvegardes, avec alerte en cas d'échec (Zabbix ou mail).
- Chaque mois : restauration de test sous un autre ID, comme en Partie 1.3, avec mesure de la durée.
- Chaque année, et avant l'audit HAS : exercice complet de sinistre (simulation de panne et restauration).
- Mise à jour par la DSI après chaque test, chaque incident réel et chaque changement d'infrastructure (nouveau serveur, nouvelle VM, nouveau prestataire), et au moins une fois par an. Chaque version est datée et validée par la direction.

PARTIE 4 — Restitution croisée

	Groupe 1	**Groupe 2**	**Groupe 3**
Stockage (NFS / ZFS)	ZFS répliqué	ZFS répliqué	NFS
RTO mesuré	Entre 2 min et 3 min 30 (promo)	Entre 2 min et 3 min 30 (promo)	2 min 17 s (panne d'un nœud)
RPO mesuré ou estimé	Jusqu'à l'intervalle de réplication (5 à 15 min)	Jusqu'à l'intervalle de réplication (5 à 15 min)	≈ 0 (HA) ; ≤ 24 h (sauvegarde)
Point unique de défaillance	Non	Non	Oui : le partage NFS hébergé sur pve (et le PC unique)

Valeurs des groupes 1 et 2 reprises du bilan de la promo présenté par le formateur.

Questions de compréhension

1. La HA est en place : pourquoi faut-il quand même des sauvegardes ?

La HA protège seulement contre la panne d'un nœud : elle relance la VM ailleurs, dans l'état où elle était. Elle ne protège pas contre une VM supprimée, des données chiffrées par un rançongiciel (la VM redémarrerait avec ses données chiffrées), une corruption, la perte du stockage NFS ou un sinistre sur le site. Seule une copie datée permet de revenir en arrière.

2. Pourquoi restaure-t-on la sauvegarde de test sous un autre numéro de VM ?

Pour ne pas écraser la VM 100 en service et protégée par la HA, et pour tester la sauvegarde sans interrompre le service. L'option Unique donne une nouvelle adresse MAC pour éviter un conflit réseau. Si la sauvegarde est mauvaise, l'original reste intact.

3. Votre sauvegarde est sur le stockage local du nœud qui héberge la VM. Que se passe-t-il si ce nœud est détruit ?

Les sauvegardes disparaissent avec le nœud. Dans notre lab, si pve2 est détruit, la HA relance VM-Test ailleurs (son disque est sur NFS), mais toutes les sauvegardes sont perdues : en cas de rançongiciel ou de suppression ensuite, il n'y aurait plus rien à restaurer. Une sauvegarde doit être sur un stockage séparé (Proxmox Backup Server sur une autre machine) avec une copie hors site : la règle 3-2-1.

4. Pour la prise de rendez-vous de Santélia, vaut-il mieux un RPO faible ou un RTO faible ? Justifiez.

Un RTO faible est prioritaire : quand le service est arrêté, les patients ne peuvent plus prendre rendez-vous et l'activité est bloquée (la panne de mars a duré plus de 6 heures). La perte de quelques rendez-vous récents se rattrape (rappel des patients, confirmations envoyées par mail ou SMS), donc un RPO de quelques heures reste acceptable. Pour les dossiers patients, c'est l'inverse : les données médicales ne doivent pas être perdues, le RPO faible devient prioritaire.

Bilan et leçons

- Une sauvegarde n'a de valeur que si sa restauration a été testée : ici, sauvegarde en 10 s et restauration prouvée en 3,6 s.
- La HA (PCA) et la sauvegarde (PRA) sont complémentaires : l'une garde le service en marche, l'autre permet de revenir en arrière.
- Le lab ne respecte pas la règle 3-2-1 : tout est sur un seul PC. En production, il faut un serveur de sauvegarde séparé et une copie hors site.
- Ressources limitées : fermer les applications inutiles avant de démarrer les 3 nœuds, et vérifier ha-manager status après chaque démarrage.